

Федеральное государственное автономное образовательное учреждение высшего
образования

«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ

«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет экономических наук

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Эмоциональные индикаторы в Telegram-каналах как фактор краткосрочного
прогнозирования инфляции в России.

по направлению подготовки Экономика
образовательная программа «Экономика»

Выполнил:

Студент группы БЭК227

Раднаев Булат Эрдэмович

Руководитель:

Доцент департамента

прикладной экономики

Станкевич Иван Павлович

степень, звание, должность Ф.И.О.

Москва 2026

Оглавление

Аннотация	3
1 Введение	5
2 Обзор литературы.....	9
3 Данные	17
4 NLP-методология: классификатор эмоций	28
5 Эконометрический анализ	42
6 Заключение.....	58
Описание применения генеративных моделей.....	66
Список литературы.....	67

Аннотация

Данная работа посвящена анализу информационной ценности многомерных эмоциональных индикаторов, извлекаемых из русскоязычных финансовых Telegram-каналов, для краткосрочного прогнозирования инфляции в России. Исследование находится на стыке макроэкономики, поведенческих финансов и обработки естественного языка. В работе предложен и применен подход, сочетающий дообучение трансформерной модели через дистилляцию знаний от большой языковой модели (teacher-student архитектура, шестиклассовая классификация) и инструменты эконометрики временных рядов: динамическую факторную модель Stock-Watson, тесты на причинность по Грейнджеру, разложение дисперсии прогнозных ошибок и out-of-sample прогнозный эксперимент с тестом Diebold-Mariano.

Получены три основных результата. Динамическая факторная модель на смешанной панели «компоненты ИПЦ $\times$ эмоциональные индикаторы» извлекает самостоятельный эмоциональный фактор, не сводимый к общеинфляционному (то есть данный фактор нагружается преимущественно на эмоциональные индикаторы, а не на общее движение компонент ИПЦ, и содержательно интерпретируется как «эмоциональный фактор»). Обнаружена статистически значимая причинность по Грейнджеру от отдельных эмоциональных классов к инфляции на горизонте нескольких месяцев, причем этот сигнал размывается при агрегации эмоций в общий фактор. Статистически значимое превосходство в out-of-sample прогнозе над авторегрессионными бенчмарками не достигается, что согласуется с известным forecasting paradox для инфляции в развитых экономиках. Научная новизна работы состоит в применении многомерной аффективной таксономии вместо бинарной тональности, дистилляции знаний из большой языковой модели в компактный трансформер для русскоязычных финансовых текстов и методологическом выводе о потере

информативного сигнала при линейной агрегации многомерных эмоциональных индикаторов.

Ключевые слова: прогнозирование инфляции, поведенческая экономика, обработка естественного языка, дистилляция знаний, динамическая факторная модель, причинность по Грейнджеру, эмоциональные индикаторы.

1 Введение

Краткосрочное прогнозирование инфляции остается одной из центральных задач макроэкономической практики. От точности таких прогнозов зависят и решения центрального банка по ключевой ставке, и поведение экономических агентов, формирующих свои инфляционные ожидания. После перехода Банка России к инфляционному таргетированию в 2014 году требования к качеству прогнозов выросли, а события 2022 и последующих лет сделали задачу еще сложнее. Волатильность ИПЦ резко увеличилась, и традиционные эконометрические модели, опирающиеся на стандартные макроэкономические предикторы, начали давать сбои.

На этом фоне в международной литературе развивается направление, использующее альтернативные источники информации, в первую очередь высокочастотные текстовые данные. Цифровизация публичного дискурса породила огромные массивы текстов, в которых экономические агенты так или иначе оценивают текущее и ожидаемое состояние экономики. Применение методов обработки естественного языка позволяет извлекать из этих текстов количественные индикаторы настроений, которые могут опережать стандартные макропоказатели и содержать информацию, не отраженную в традиционных рядах.

В России Telegram занимает особое место среди подобных источников. К 2024–2025 годам финансовые Telegram-каналы, от официального канала Банка России до известных частных аналитиков, формируют значительную часть публичного дискурса об инфляции, ставке и экономической политике. Этот дискурс далеко не нейтрален. Помимо рациональной оценки фактов в нем отчетливо присутствует эмоциональный компонент: тревожность из-за обесценения сбережений, разочарование в действиях властей, надежда на стабилизацию или, наоборот, неопределенность относительно будущего. Через каналы потребления, ценообразования и инвестиционных решений эти эмоциональные состояния в конечном счете могут влиять на динамику цен.

При этом существующие эконометрические работы, использующие текстовый сигнал, преимущественно ограничиваются бинарной классификацией «позитив-негатив» либо словарными методами, разработанными для англоязычных финансовых текстов. На русскоязычные неформальные тексты из социальных медиа эти методы переносятся плохо. Современные большие языковые модели и трансформерные архитектуры открывают возможность для гораздо более тонкого, многомерного анализа эмоционального содержания. Однако их систематическое применение к задачам российской макроэкономической эконометрики на момент написания данной работы фактически отсутствует.

Цель настоящей работы заключается в определении информационной ценности многомерных эмоциональных индикаторов, извлекаемых из русскоязычных финансовых Telegram-каналов методами глубокого NLP-анализа, для краткосрочного прогнозирования инфляции в России на горизонтах от 1 до 6 месяцев. Эта цель распадается на три задачи. Первая, разработать многоклассовый классификатор эмоций для русскоязычных финансовых текстов, учитывающий специфику доменного языка и переносимый на разные источники. Вторая, проверить, образуют ли извлеченные эмоциональные индикаторы самостоятельное измерение в макроэкономических данных, не сводимое к собственной структуре инфляции. Третья, оценить, существует ли значимая опережающая связь между эмоциональными индикаторами и инфляцией, и переносится ли эта связь в улучшение прогнозной точности по сравнению с авторегрессионными бенчмарками.

Объектом исследования выступает краткосрочная динамика индекса потребительских цен в России и формирующих его компонентов в период с января 2020 по март 2026 года. **Предмет** исследования, информационная связь между эмоциональными индикаторами, извлеченными из российских финансовых Telegram-каналов, и инфляционной динамикой.

В работе формулируются и проверяются три гипотезы.

H1: эмоциональные индикаторы Telegram-каналов формируют самостоятельное измерение, не сводимое к структуре инфляционных компонентов.

H2: первые разности эмоциональных индикаторов предсказывают по Грейнджеру месячную инфляцию на горизонтах 1–4 месяцев.

H3: включение эмоциональных индикаторов в эконометрические модели прогнозирования инфляции улучшает out-of-sample прогнозную точность по сравнению со стандартными авторегрессионными бенчмарками.

Научная новизна работы связана с несколькими элементами. Во-первых, для эконометрического анализа российских финансовых текстов впервые применяется многомерная таксономия эмоций, шесть классов вместо стандартной бинарной тональности или словарных подходов. Во-вторых, реализована техника дистилляции знаний из большой языковой модели в компактный трансформер для русскоязычных финансовых текстов; качество классификации валидируется через leave-one-channel-out cross-validation. В-третьих, предложена смешанная панельная спецификация динамической факторной модели, в которую одновременно входят микродекомпозиция инфляции (53 компонента ИПЦ) и эмоциональные индикаторы из социальных медиа; в этой панели обнаруживается четко идентифицируемый «эмоциональный фактор», независимый от общеинфляционного. Наконец, систематически сопоставляется эффект на агрегированном уровне (фактор) и на уровне отдельных эмоций, и здесь обнаруживается важный методологический результат: значимая причинность по Грейнджеру проявляется на уровне индивидуальных эмоциональных категорий, но размывается при их линейной агрегации.

Практическая значимость определяется тем, что разработанный шестиклассовый классификатор эмоций для русскоязычных финансовых текстов и построенная панель ежедневных эмоциональных индикаторов

могут быть полезны аналитикам для качественного мониторинга настроений экономических агентов в режиме, близком к реальному времени. Здесь стоит честно оговориться: прямое улучшение точечного прогноза инфляции эмоциональными индикаторами в данной работе как статистически значимое не подтверждается. Однако обнаруженные содержательные связи, в особенности высокий вклад неопределенности в дисперсию прогнозных ошибок инфляции, представляют самостоятельный интерес для понимания механизмов формирования инфляционных ожиданий.

Методологически работа сочетает инструменты из трех областей. Из NLP применяется дообучение трансформерной модели DeepPavlov rubert-base-cased-conversational с focal loss для несбалансированных классов и leave-one-channel-out cross-validation для проверки кросс-доменной обобщающей способности. Из эконометрики временных рядов используются тесты единичного корня, динамическая факторная модель в спецификации Stock и Watson (2002), парные и мультивариантные тесты на причинность по Грейнджеру, векторная авторегрессия с импульсными функциями отклика и FEVD, Bayesian VAR с приорами Миннесоты, а также регуляризованная регрессия Elastic Net. Из области прогнозирования применяются rolling forecast с расширяющимся окном, метрики RMSFE и MAE, а также тест Diebold, Mariano (1995) с поправкой Harvey-Leybourne-Newbold (1997) для малых выборок.

2 Обзор литературы

Настоящая работа лежит на пересечении трех направлений: прогнозирования инфляции в макроэконометрике, теоретического анализа формирования экономических ожиданий в условиях ограниченного внимания, а также применения методов NLP к финансовым текстам. Постановка задачи предполагает соединение этих линий исследования, поэтому обзор организован тематически: от теоретических оснований к методам прогнозирования инфляции, и далее к работам по текстовому анализу и связанным с ним эмпирическим результатам.

2.1 Теоретические основания: ожидания и информационные жесткости

Теоретическим фундаментом для использования эмоциональных индикаторов в задачах макропрогнозирования служит литература об информационных жесткостях. В работе Sims (2003) предложена концепция рационального невнимания: экономические агенты обрабатывают поступающую информацию через канал ограниченной пропускной способности, что приводит к инерции реакций цен, потребления и инвестиционных решений на макроэкономические шоки. Параллельно, но с другим микрооснованием, в Mankiw, Reis (2002) развивается модель жесткости информации, в которой агенты обновляют ожидания не непрерывно, а с задержкой.

Эмпирическое подтверждение информационных жесткостей в данных профессиональных прогнозистов приведено в Coibion, Gorodnichenko (2015): авторы показывают, что отклонения от полной информационной рациональности систематически проявляются в прогнозных ошибках, причем степень информационной жесткости меняется во времени и между странами. На этом фоне правдоподобной выглядит гипотеза, что наблюдаемые в публичном дискурсе настроения, особенно категории, связанные с неопределенностью и тревожностью, могут

содержать информацию об инфляционной динамике, которой нет в стандартных макроиндикаторах. Поведенческая экономика дополняет эту картину: эмоциональные состояния, зафиксированные в текстах, отражают не случайный шум, а самостоятельные факторы формирования экономических решений. Эта идея во многом определила выбор шести классов эмоций в нашем классификаторе.

2.2 Прогнозирование инфляции и парадокс простых моделей

Базовым ориентиром в литературе по прогнозированию инфляции остается работа Atkeson, Ohanian (2001). В ней показано, что традиционные модели на основе кривой Филлипса не превосходят простой наивный прогноз «инфляция в следующем году будет такой же, как в предыдущем» на американских данных. Этот результат, на удивление прочный, поставил под сомнение практическую ценность многих многомерных моделей и сформировал стандарт оценки прогнозов через сравнение с авторегрессионными бенчмарками.

В Stock, Watson (2007) сюжет получает развитие. Авторы показывают, что инфляция в США стала «труднее прогнозировать» начиная с середины 1980-х годов, а одномерная UCSV-модель (unobserved components stochastic volatility) с трендовой составляющей и стохастической волатильностью оказывается одним из лучших бенчмарков. Это превосходство простых моделей над сложными известно в литературе как «forecasting paradox» и многократно воспроизводилось в последующих работах. Применительно к настоящему исследованию это означает простую вещь: любая модель, включающая эмоциональные индикаторы, должна оцениваться против сильных одномерных бенчмарков (RW, AR, ARIMA) с помощью формального теста Diebold, Mariano (1995). И, что важно, отсутствие значимого превосходства не следует автоматически трактовать как опровержение содержательной гипотезы о связи эмоций и инфляции; оно может отражать общую сложность краткосрочного прогноза.

2.3 Динамические факторные модели и байесовские VAR

Параллельно в макроэконометрике развивается подход на основе динамических факторных моделей (DFM). Идея заключается в извлечении ограниченного числа латентных факторов из больших панелей макропеременных. В базовой работе Stock, Watson (2002) показано, что прогнозы на основе диффузных индексов (PCA-факторов) на 215 макропредикторах превосходят одномерные авторегрессии и небольшие VAR на американских данных. Теоретическое обоснование состоятельности факторных оценок при больших T и N приведено в Bai, Ng (2002); там же предложены три информационных критерия для выбора числа факторов в приближенных факторных моделях.

Развитие подхода на случай произвольного паттерна пропущенных данных, что существенно для real-time приложений с разной частотой публикации индикаторов, представлено в Bańbura, Modugno (2014). Авторы предлагают модификацию EM-алгоритма для оценивания DFM с помощью фильтра Калмана. Эта линия методологии напрямую используется в нашей работе: на смешанной панели «инфляционные компоненты × эмоциональные индикаторы» оцениваются и PCA-факторы, и Kalman-факторы по схеме Bańbura и Modugno, а число факторов выбирается по критериям Bai и Ng. Альтернативой факторному подходу для больших наборов предикторов выступают байесовские векторные авторегрессии. В Bańbura et al. (2010) показано, что VAR с приорами Миннесоты в стиле Литтермана при правильной настройке силы сжатия дает сопоставимое или лучшее качество прогнозов по сравнению с факторными моделями. Байесовское сжатие особенно эффективно при малых выборках, где OLS-оценки нестабильны. Это методологически важно для нашей задачи: 74 месячных наблюдений, это та выборка, на которой стандартный VAR с эмоциями страдает от переобучения, и BVAR-Minnesota становится естественным компромиссом между структурной интерпретируемостью VAR и регуляризацией.

2.4 Текстовый анализ в финансах: от словарей к трансформерам

Применение количественного текстового анализа в финансовой экономике принято отсчитывать от работы Tetlock (2007). В ней показано, что измеренный по словарному методу пессимизм в колонке «Abreast of the Market» Wall Street Journal предсказывает краткосрочную динамику Dow Jones Industrial Average. Эта работа задала методологический стандарт, который воспроизводится до сих пор: текстовый сигнал агрегируется до временного ряда, после чего тестируется на связь с финансовыми переменными через регрессию доходностей на лаговый сентимент-индикатор. Развитие словарного метода представлено в Loughran, McDonald (2011). Авторы показывают, что общелингвистические тональные словари, в частности Harvard Dictionary, систематически ошибаются на финансовых текстах: около трех четвертей слов, помеченных как «негативные» в общем словаре, не несут негативной коннотации в финансовом контексте. В качестве решения предлагается набор финансово-адаптированных словарей. Этот результат служит важной мотивацией для нашего собственного выбора инструмента: бинарная тональность, измеренная общелингвистическими методами, на финансовых текстах систематически искажает сигнал, и многомерная классификация с помощью дообученной модели представляется методологически более обоснованной.

Современная парадигма в текстовом анализе финансовых данных опирается на трансформерные нейросетевые модели. В Araci (2019) предложен FinBERT, модель на основе BERT, дообученная на финансовых текстах для задачи сентимент-анализа. Автор показывает, что доменно-адаптированная модель превосходит общелингвистические модели на стандартных бенчмарках (Financial PhraseBank, FiQA), и что даже ограниченной разметки достаточно для качественной классификации при использовании предобучения. Этот результат служит концептуальной основой для нашего подхода. Поскольку FinBERT доступен только для английского языка, мы дообучаем русскоязычную модель DeepPavlov

rubert-base-cased-conversational (Kuratov, Arkhipov, 2019), предобученную на разговорных русских текстах из корпусов OpenSubtitles, Pikabu и Taiga, что обеспечивает близость доменного распределения к Telegram-каналам. Архитектурно мы используем дистилляцию знаний из большой языковой модели в компактный трансформер по схеме Hinton et al. (2015): большая языковая модель GigaChat в режиме few-shot-промптинга играет роль teacher-разметчика, а компактная модель-ученик обучается на полученных мягких метках. Для борьбы с дисбалансом классов применяется focal loss из Lin et al. (2017), изначально предложенный для задач object detection с экстремальным дисбалансом, но успешно применяемый и в задачах классификации текстов с редкими категориями.

2.5 Текстовые индикаторы и макроэкономика

Применение текстовых индикаторов настроений к собственно макроэкономическим переменным, направление сравнительно молодое. В Shapiro et al. (2022) построен индекс новостной экономической тональности на корпусе из 16 крупных американских газет с 1980 по 2015 годы. Авторы используют комбинацию словарных методов с учетом отрицания и доменно-специфического словаря, и показывают, что построенный индекс содержит прогностический сигнал для ВВП и потребительского доверия, не покрываемый стандартными макропоказателями.

Близкая по духу линия исследований развивается на данных социальных медиа. В Bollen et al. (2011) показано, что измеренное по шестимерной шкале «настроение» в Twitter содержит причинный по Грейнджеру сигнал для движения индекса Dow Jones. Эта работа породила обширную, хотя и спорную литературу о социальных медиа как опережающих индикаторах. Стоит отметить попытку репликации в Lachanski, Pav (2017): авторы показывают, что результат Bollen et al. (2011) чувствителен к выбору окна и спецификации. В свете этого критического опыта особое внимание в настоящей работе уделено дизайну валидации, в

частности, кросс-доменной валидации классификатора и тесту Diebold, Mariano для прогнозного сравнения моделей.

Особое место в литературе занимают индексы неопределенности, построенные на новостных корпусах. В Baker et al. (2016) предложен индекс экономической политической неопределенности (Economic Policy Uncertainty, EPU), основанный на частоте упоминаний ключевых терминов в крупнейших американских газетах. Авторы показывают, что шоки EPU оказывают значимое отрицательное влияние на инвестиции и занятость в чувствительных к политике секторах. Развитие этого подхода для денежно-кредитной политики представлено в Husted et al. (2020). Авторы строят аналогичный индекс монетарной неопределенности (MPU) и показывают его связь с реальной экономической активностью и финансовыми рынками. Эта линия результатов методологически важна для настоящей работы: одна из шести классифицируемых нами эмоций, «неопределенность», измеряется не по словарной частоте, а через классификацию текстов трансформерной моделью. Это позволяет уловить семантически выраженную, но лексически разнообразную неопределенность. Обнаруженная в нашем эмпирическом анализе двусторонняя причинность по Грейнджеру между Uncertainty и инфляцией согласуется с теоретическим представлением о петле обратной связи между неопределенностью и реальной ценовой волатильностью, к которому в литературе пришли через индекс MPU.

2.6 Российский контекст и пробелы в литературе

Применительно к российскому контексту опыт использования NLP-методов в анализе финансовых текстов остается ограниченным. Одной из немногих работ в этой области является исследование Teplova, Tomtosov, Sokolova (2022). Авторы используют нейронные сети для оценки тональности сообщений российских розничных инвесторов из социальных сетей и предлагают индикатор Нуре, объединяющий метрики внимания и сентимента. Результаты показывают, что сентимент розничных инвесторов является значимым фактором, объясняющим доходности акций на

российском фондовом рынке. Этот результат подтверждает применимость NLP-методов к русскоязычным неформальным финансовым текстам, но макроэкономическое применение подобных индикаторов, то есть связь сентимента не с финансовыми инструментами, а с инфляцией или другими макропоказателями, в литературе на русском языке, насколько известно автору, практически отсутствует. Настоящее исследование расширяет российскую традицию NLP-анализа финансовых текстов в макроэкономическое измерение, а также переходит от бинарной или одномерной тональности к шестимерной аффективной таксономии.

Применительно непосредственно к задаче прогнозирования российской инфляции центральная свежая работа — Волгина (2025), опубликованная в журнале Банка России «Деньги и кредит». Автор использует новостные индексы в моделях машинного обучения для прогнозирования российской инфляции на горизонтах 1–6 месяцев и показывает, что добавление текстового новостного сигнала к стандартным макропеременным улучшает прогнозную точность. Это подтверждает применимость текстовых индикаторов к российской макроэкономической задаче и одновременно ставит вопрос о том, какие именно компоненты текстового сигнала несут опережающую информацию. Данная работа отвечает на этот вопрос с другой стороны: вместо новостных СМИ используются финансовые Telegram-каналы, и вместо одномерного индекса тональности — многомерная аффективная таксономия из шести классов.

Из более ранних исследований методологически близка работа Mikosch, Solanko (2017) для прогнозирования российского ВВП с помощью смешанных частот данных в духе MIDAS-моделей. Авторы показывают, что среди нефинансовых индикаторов существенный вклад в прогноз дают денежно-банковские переменные, а не только нефть и валютный курс. Это создает методологический контекст для нашей работы: эмоциональные индикаторы из социальных медиа могут рассматриваться как еще один

класс «нестандартных» опережающих индикаторов российских макропоказателей.

Таким образом, можно выделить три пробела, которые работа заполняет. Первый, методологический: переход от бинарной тональности к многомерной аффективной таксономии для финансовых текстов. Второй, данных: применение Telegram-каналов как источника эмоционального сигнала, в дополнение к новостным индексам Волгиной (2025) и форумам Terlova et al. (2022). Третий, эконометрический: тестирование причинности по Грейнджеру не только на агрегированном эмоциональном факторе, но и отдельно для каждой из шести аффективных категорий, что, как показано в Разделе 5, дает принципиально разные результаты.

3 Данные

В этом разделе описано, какие данные используются в работе, как они собирались и обрабатывались, а также как устроена общая логика анализа. Поскольку в работе соединяются два разнородных источника (тексты из Telegram и официальная макростатистика), раздел построен так. Сначала рассмотрены текстовые данные и процедура их сбора. Затем подробно разобраны макроэкономические ряды и их свойства. В конце сформулирована эмпирическая стратегия и обоснованы границы окна анализа.

3.1 Текстовые данные

Текстовый корпус собран из шести русскоязычных Telegram-каналов финансово-экономической направленности. Список каналов и их основные характеристики приведены в Таблице 3.1. Выбор каналов основан на трех критериях: устойчивая аудитория от 30 тыс. подписчиков (исключение, @swanecomony на ранних периодах), регулярные публикации без длинных пропусков и тематика, в которой систематически обсуждаются инфляция, ключевая ставка, курс рубля и потребительское поведение.

Канал	Профиль	Сообщений в выборке	Подписчиков (на 03-2026)
@centralbank_russia	Официальный канал Банка России	около 4,5 тыс.	около 130 тыс.
@russianmacro	Макроэкономическая аналитика, обзоры решений ЦБ	около 21 тыс.	около 80 тыс.
@bitkogan	Е. Коган, частная инвестиционная аналитика	около 35 тыс.	около 320 тыс.

Канал	Профиль	Сообщений в выборке	Подписчиков (на 03-2026)
@spydell_finance	Разбор глобальных рынков и российской макро	около 33 тыс.	около 100 тыс.
@swaneconomy	Авторский канал по макротематике	около 5 тыс.	около 35 тыс.
@Coin_Post	Криптовалюты и фондовый рынок (с обсуждением рублевой инфляции)	около 545 тыс.	около 95 тыс.

Таблица 3.1. Источники текстовых данных

Структура выборки балансирует три типа авторства. Это официальная коммуникация регулятора (@centralbank_russia), профессиональная аналитика (@russianmacro, @spydell_finance, @swaneconomy) и публичная аналитика с выраженной авторской позицией (@bitkogan, @Coin_Post). Такое распределение оправдано теоретически: разные эмоциональные регистры формируют разные стороны дискурса, и сведение всех каналов к одному типу могло бы дать систематически смещенную оценку. Отдельного комментария заслуживает канал @Coin_Post. Формально это криптовалютный канал, но в нем систематически появляются обсуждения российской инфляции, курса рубля и решений Банка России. Вручную была просмотрена случайная выборка из 200 сообщений и оценена доля «чисто крипто» постов в районе 22%. Этот канал добавляет в корпус значительный объем (около 545 тыс. сырых сообщений против 35 тыс. у @bitkogan), и его влияние на агрегированный сигнал отдельно проверяется в разделе 5.7 на робастность.

Сбор сообщений выполнен на Python через библиотеку telethon (это асинхронный клиент для MTProto API Telegram). Метод iter_messages обходит каждый канал от самого раннего доступного поста и складывает

результаты в parquet-файл. Сырая выгрузка получилась около 643 тыс. сообщений за период с 01-2017 по 03-2026. Каждое сообщение сохраняется вместе с метаданными: ID канала, ID сообщения, дата и время, длина текста, число просмотров (там, где Telegram его возвращает), наличие медиавложений, ID реплая для отслеживания цепочек.

3.2 Предобработка корпуса текстов

Сырые данные нужно довольно сильно отфильтровать, прежде чем подать на классификатор. Применены пять последовательных шагов. Удаление пустых сообщений и текстов короче 30 символов, ниже которых классификация эмоций становится ненадежной. Фильтрация технических постов: опросы, репосты без комментария автора, сообщения, состоящие только из ссылок. Нормализация текста: приведение к нижнему регистру, замена URL на токен <URL>, упоминаний пользователей на <USER>, восстановление пропущенных букв «е». Дедупликация near-duplicates по Jaccard-схожести n-грамм с порогом 0.85, реализованная через библиотеку simhash. И наконец, усечение до окна анализа. Результаты по этапам в Таблице 3.2.

Этап обработки	Сообщений (тыс.)	Доля от исходных
Сырая выгрузка из Telegram через telethon	около 643	100,0%
Очистка от пустых и коротких текстов	около 580	90,2%
Убраны технические посты (опросы, чистые ссылки, репосты)	около 542	84,3%
Дедупликация near-duplicates (Jaccard 0.85)	около 521	81,0%
Усечение до окна анализа 02-2020 - 03-2026	около 478	74,3%

Таблица 3.2. Объемы корпуса по этапам предобработки

После всех этапов в анализ заходит около 478 тыс. сообщений за окно 02-2020-03-2026. Дедупликация на пороге 0.85 удалила относительно небольшой кусок (около 3.3% от данных после фильтрации). Это объясняется тем, что финансовые Telegram-каналы редко публикуют буквально идентичные тексты. Большинство near-duplicates, которые были обнаружены, это перепосты официальных коммуникаций ЦБ через несколько каналов, которые корректнее учесть один раз. Все этапы реализованы в pandas 2.x с регулярными выражениями re и simhash для оценки расстояний.

3.3 Дескриптивный анализ

Чтобы понять, как корпус устроен во времени, были построены Рис. 3.1. На верхней панели показано общее количество сообщений в день по всем шести каналам сразу (синяя тонкая линия это сырое значение, темно-синяя жирная это 30-дневный rolling median). Шкала логарифмическая, потому что без нее ранние периоды просто сливаются с осью. Красная пунктирная линия отмечает порог в 20 сообщений в день, ниже которого ручной просмотр случайной выборки показал, что дневной сигнал получается слишком шумным для надежной оценки эмоциональных индикаторов. На нижней панели та же информация, но с разбивкой по каналам.




Рис. 3.1. Объем сообщений в день по корпусу: общий поток (верхняя панель) и в разбивке по каналам (нижняя панель). Логарифмическая шкала по оси Y.

Из Рис. 3.1 видны три важные вещи. Во-первых, в феврале 2022 года происходит резкий структурный сдвиг по объему публикаций. Суммарный поток сообщений в день вырастает с медианных 30-40 до медианных 600-700, то есть примерно в 20 раз. Сдвиг сохраняется до конца периода наблюдения и, очевидно, связан с внешнеэкономическими событиями февраля 2022 года, после которых тема экономической политики становится центральной во всех каналах одновременно. Это не баг данных, это особенность, которую обязательно надо учесть в моделях. Бессмысленно сравнивать «эмоциональный фон» в январе 2020 года и в январе 2023 года в абсолютных терминах, потому что даже при одной и той же средней доле тревожных сообщений в день абсолютное число тревожных сообщений вырастет в 20 раз. Поэтому в работе используются нормированные ряды (доли), а не абсолютные частоты, и в эконометрических спецификациях вводится бинарная *dummy*-переменная *D_2022* для разделения двух режимов. После сдвига попадает 50 месячных наблюдений из 74, до сдвига 24.

Во-вторых, видно, что разные каналы запускались в разное время. *@bitkogan* и *@russianmacro* работают стабильно с 2018 года, *@Coin_Post* стартует в конце 2017 года, *@spydell_finance* делает резкий скачок объемов в феврале 2022 года, *@centralbank_russia* становится активным с конца 2022 года, а *@swanecconomy* с 2023 года. Это объясняет выбор начала окна анализа: до 2020 года часть каналов либо не существовала, либо публиковала слишком мало для дневной эмоциональной агрегации. В-третьих, между каналами различается интенсивность публикаций. Если в первой половине 2022 года один *@spydell_finance* публикует около 600 сообщений в день, то у остальных каналов уровень в десять-сто раз ниже. Без какой-то поправки агрегированный сигнал будет систематически смещен в сторону наиболее «громкого» канала.

Распределение длин сообщений имеет тяжелый правый хвост. Медианная длина около 380 символов, среднее около 720, 95-й перцентиль около 2400. Длинные посты, как правило аналитические разборы решений ЦБ или подробные комментарии к статистике, по моему наблюдению на ручной разметке несут более насыщенный эмоциональный сигнал, чем короткие. Это будет учтено при агрегации эмоций до временных рядов: помимо простого среднего по сообщениям дня (*mean*), считается среднее, взвешенное по длине текста в токенах (*wmean*).

3.4 Макроэкономические данные

Целевая переменная - это индекс потребительских цен в трех формах. Первая, общий ИПЦ месяц-к-месяцу с устраненной сезонностью. Источник, таблица «Темпы прироста потребительских цен, в процентах к предыдущему месяцу, сезонность устранена», которую публикуют Росстат и Банк России в составе индикаторов мониторинга финансовой устойчивости. Вторая, ИПЦ год-к-году (*уоу*), используется для робастности. Третья и центральная для работы, микродекомпозиция инфляции на 53 компонента. Среди них 28 позиций продовольствия, 18 непродовольственных товаров и 7 услуг. Все компоненты доступны в формате темпов прироста м/м с устраненной сезонностью с 01-2002 по 03-2026 (общая длина 290 месяцев в исходных данных). Эта микродекомпозиция нужна для динамической факторной модели: на уровне головного ИПЦ факторная декомпозиция вырождается, а на 53 компонентах с разной экономической природой (плодоовощная продукция, регулируемые тарифы, импортируемые товары, рыночные услуги) факторная структура становится содержательно интерпретируемой.

На Рис. 3.2 показана динамика основных агрегатов ИПЦ с 2002 года. На верхней панели общий ИПЦ (черная линия) и базовый ИПЦ (без волатильных компонентов: плодоовощной продукции, нефтепродуктов и регулируемых ЖКХ-тарифов, красная линия). На нижней панели разбивка на три группы: продовольственные товары, непродовольственные и услуги.

Графики идут с 2002 года, чтобы показать долгосрочный контекст: окно анализа работы (02-2020, 03-2026) это правая часть графика.




Рис. 3.2. Динамика общего и базового ИПЦ м/м (верхняя панель) и трех групп товаров и услуг (нижняя панель). Источник: Банк России.

Во-первых, до 2014 года инфляция в России держалась в довольно узком коридоре около 0,5-1,5% в месяц с устраненной сезонностью, с двумя локальными пиками в 2008 и 2014 годах. Во-вторых, после 2014 года и особенно после введения инфляционного таргетирования траектория становится более контролируемой, общий ИПЦ редко выходит за 1,5%. В-третьих, исключительный пик марта 2022 года: общий ИПЦ достигает почти 9% м/м, что является многолетним максимумом. Интересно, что базовый ИПЦ (красная линия) показывает сопоставимый пик. Значит, скачок 2022 года — это не только результат разовых шоков по плодоовощам или нефтепродуктам, базовая инфляция тоже резко выросла. На нижней панели хорошо видно, что в марте 2022 года максимальный скачок (около 11% м/м) пришелся на непродовольственные товары, а не на продовольствие. Это согласуется с экономической интерпретацией: непродовольственные товары имеют наиболее высокую долю импорта, и их

цены оказались чувствительнее всего к изменениям курса и логистических цепочек.

Сводная статистика по общему ИПЦ за окно анализа в Таблице 3.3 показывает важный факт. До 02-2022 среднее значение составляет 0,560 при стандартном отклонении 0,222. После 02-2022 среднее почти не меняется (0,698), но стандартное отклонение растет почти в пять раз, до 1,049. То есть с точки зрения средних инфляция вернулась к норме, но с точки зрения волатильности это уже другой процесс. Этот факт сильно влияет на интерпретацию результатов

Период	N	Среднее	Std	Min	Max
Полная выборка	74	0,653	0,871	-0,316	7,495
До 02-2022 (D=0)	24	0,560	0,222	0,143	0,910
После 02-2022 (D=1)	50	0,698	1,049	-0,316	7,495

Таблица 3.3. Сводная статистика общего ИПЦ м/м по периодам

3.5 Предварительный анализ связи эмоций и инфляции

Прежде чем переходить к формальной эконометрике, полезно посмотреть на простые лаговые корреляции между эмоциональными индикаторами и общим/базовым ИПЦ. Это дает интуицию, чего ожидать от тестов на причинность по Грейнджеру. На Рис. 3.3 показаны корреляции Пирсона эмоциональных рядов (доли каждого из шести классов плюс entropy и log_msg_volume) с двумя инфляционными рядами на четырех лагах. Лаг 0 это совпадающий месяц, лаг 1 — это эмоция в текущем месяце против инфляции через месяц, и так далее.




Рис. 3.3. Лаговые корреляции Пирсона между эмоциональными индикаторами и общим/базовым ИПЦ. Лаг k означает, что эмоция в момент t коррелирует с инфляцией в момент $t+k$.

На лаге 0 (совпадающий месяц) корреляции почти все близки к нулю, в диапазоне от -0,10 до +0,13. Это уже само по себе интересно: то, что эмоциональный фон в этом месяце слабо связан с инфляцией в этом же месяце, говорит о том, что мгновенные совпадения не доминируют в данных, и опережающая структура (если она есть) проявится только на положительных лагах. На лагах 1, 2 и 3 картина становится более выразительной. Сильнее всего корреляция растет у Uncertainty: 0,22 на лаге 1, 0,29 на лаге 2 (с общим ИПЦ) и 0,31 (с базовым). Это самые большие по модулю значения на всей карте, и они согласуются с теоретическим представлением о том, что неопределенность потребителей и аналитиков должна работать как опережающий индикатор. У Anxiety корреляции тоже положительные и заметные (0,15-0,16 на лаге 1), но затухают быстрее. Aggression и Disappointment, наоборот, дают отрицательные корреляции с инфляцией, в районе -0,18 до -0,24. Норе практически нейтрален.

Эти лаговые корреляции — это, конечно, не доказательство опережающей связи: корреляция не учитывает автокорреляцию инфляции и, может быть, ложность в условиях структурного сдвига. Полноценный тест на причинность по Грейнджеру с учетом этих факторов делается в Разделе 5. Но Рис. 3.3 дает ясное предварительное указание, какие именно

классы эмоций стоит изучать в первую очередь: это Uncertainty и в меньшей степени Anxiety. Aggression и Hope, скорее всего, окажутся реактивными, а не опережающими, и формальные тесты позже это подтверждают.

3.6 Эмпирическая стратегия

Общая логика анализа выстроена в четыре шага. Первый: построение многомерных эмоциональных индикаторов из текстов через NLP-классификатор на 6 классов. Это содержание раздела 4. На выходе получается таблица из 14 ежедневных рядов, которые далее агрегируются до месячной частоты. Второй: оценка динамической факторной модели на смешанной панели «53 компонента ИПЦ + 8 эмоциональных индикаторов». Это дает возможность проверить гипотезу H1 о наличии самостоятельного «эмоционального измерения», независимого от структуры инфляции. Третий: тесты причинности по Грейнджеру на двух уровнях, между факторами и между отдельными эмоциями и инфляцией. Это проверяет H2 и одновременно показывает, на каком уровне агрегации проявляется опережающий сигнал. Четвертый: out-of-sample прогнозный эксперимент с семью моделями (Random Walk, AR, ARIMA, VAR с эмоциями, BVAR-Minnesota, ElasticNet-VAR) и тестом Diebold-Mariano. Конкретные параметры прогнозного эксперимента следующие: тестовый период охватывает 27 месяцев с февраля 2024 года по март 2026 года. Используется схема расширяющегося окна (expanding window): первая обучающая выборка — наблюдения 1–48 (02-2020 по 01-2024), затем после каждого прогнозного шага окно расширяется на один месяц. Прогнозные горизонты: $h = 1, 3, 6$ месяцев. Метрики качества — RMSFE и MAE. Формальное сравнение моделей с бенчмарком Random Walk выполняется через тест Diebold-Mariano с поправкой Harvey-Leybourne-Newbold для малых выборок. Это дает ответ на H3.

Окно анализа, 74 месячных наблюдения с 02-2020 по 03-2026, выбрано исходя из двух соображений. Более ранняя точка отсечки

нежелательна, потому что до 2020 года Telegram как массовая платформа для финансово-экономического дискурса в России только формировался. Это видно и на Рис. 3.1: до 2020 года несколько каналов либо не существовали, либо публиковали слишком мало для дневной агрегации. С другой стороны, более раннее начало означало бы смешивание предтаргетингового периода с режимом инфляционного таргетирования, что сместило бы оценки. То есть 74 месяца — это компромисс между размером выборки и однородностью режима. Это же одновременно и ограничение работы, особенно для BVAR на 60+ переменных.

Все вычисления выполнены на Python 3.11 со стандартным стеком: pandas, numpy, statsmodels, scikit-learn, transformers и torch. Дообучение NLP-классификатора шло на одной видеокарте NVIDIA T4 (16 ГБ VRAM) в Google Colab. Полное время обучения финальной 6-классовой модели составило около 4 часов с учетом всех чекпоинтов и temperature scaling.

4 NLP-методология: классификатор эмоций

Этот раздел описывает разработку и обучение классификатора, который формирует сердцевину эмпирической части работы.

4.1 Таксономия эмоций

Выбор таксономии — это первый и довольно ответственный методологический шаг. Стандартный подход в финансовом NLP это бинарная тональность «позитив/негатив» в духе Loughran, McDonald (2011). Для нашей задачи он не подходит по двум причинам. Первая, как обсуждалось во Введении и Обзоре литературы, бинарная тональность не позволяет различить содержательно разные настроения: тревожность из-за инфляции, агрессия в адрес ЦБ и разочарование в политике все три попадут в один «негативный» бакет, теряя различающий сигнал. Вторая, и это эмпирически важно: на 74-месячных наблюдениях один негативный индикатор с высокой вероятностью окажется неотличим от обычной волатильности инфляции, а отдельные категории сохраняют шанс на содержательную идентификацию.

Шесть классов: Aggression, Anxiety, Disappointment, Hope, Neutral, Uncertainty это компромисс. Из них Anxiety и Uncertainty восходят к финансово-адаптированным таксономиям в духе Tetlock (2007) и индексам неопределенности Husted, Rogers, Sun (2020). Hope и Aggression относятся к категориям, которые в финансовой экономике связываются с понятием «animal spirits» и описываются в работах Tetlock (2007), Bollen et al. (2011) и Shapiro et al. (2022) как ключевые компоненты эмоционального профиля рыночного дискурса. Disappointment относительно специфическая для нашего корпуса категория: разочарование в действиях экономических властей, отличающееся от агрессии по тону (упадок, а не атака) и от тревожности по временному фокусу (прошлое, а не будущее). Neutral это базовая категория. Содержательное описание каждого класса с типичными примерами в Таблице 4.1.

Класс	Описание	Пример
Aggression	Резкая критика политики, обвинения, конфронтационная риторика	«Очередной бессмысленный шаг ЦБ, который только усугубит ситуацию»
Anxiety	Тревога, опасения, ожидание ухудшения, страх обесценения	«Боюсь, инфляция выйдет из-под контроля, накопления тают на глазах»
Disappointment	Разочарование в результатах, недостижение ожиданий, упадок	«Опять рост цен, обещания о замедлении не работают»
Hope	Надежда на улучшение, конструктивный оптимизм, позитивное ожидание	«Жесткая ДКП постепенно сработает, есть основания для оптимизма»
Neutral	Информационная нейтральность, констатация фактов без эмоциональной окраски	«ЦБ оставил ставку на уровне 16%»
Uncertainty	Неопределенность, сомнение, оговорки о возможных исходах	«Сложно сказать, как это отразится на инфляции, слишком много факторов»

Таблица 4.1. Таксономия эмоций для классификатора

4.2 Архитектура подхода: teacher-student дистилляция

Чтобы классифицировать 478 тыс. сообщений, нужна компактная модель, которая поместится на одной видеокарте и работает быстро. Прямое использование большой языковой модели (например, GigaChat в режиме API) для классификации каждого сообщения нереалистично из-за стоимости и скорости. С другой стороны, разметить вручную хотя бы 5-10 тыс. сообщений силами одного автора это задача на несколько недель, и она не гарантирует консистентности. В такой ситуации логичнее всего использовать дистилляцию знаний из большой языковой модели в

компактный трансформер по схеме, заложенной в Hinton et al. (2015) и примененной в близком контексте к финансовым текстам в Araci (2019) для FinBERT.

«Учитель» (LLM GigaChat) размечает относительно небольшой подкорпус, 9583 сообщений, в режиме few-shot-промптинга. При этом учитель опирается на свою предобученную способность понимать тонкости русскоязычного финансового дискурса. Затем компактная «ученическая» модель (rubert-base-cased-conversational, 180 млн параметров) дообучается на этой разметке как на ground truth и далее применяется ко всему корпусу из 478 тыс. сообщений. Главное преимущество этого подхода — это масштабируемость: один раз размеченный teacher-датасет позволяет обработать корпус любого размера, а стоимость классификации каждого нового сообщения после дообучения исчисляется миллисекундами. Побочное преимущество это стабильность: одна и та же ученическая модель применяется ко всему корпусу, в отличие от прямой LLM-разметки, где даже одинаковые промпты могут давать разные результаты для повторяющихся текстов.

4.3 Teacher-разметка через GigaChat

Для teacher-разметки случайным образом отобрана выборка из 9583 сообщений. Изначально промпт был на 4 классах (Aggression, Anxiety, Hope, Neutral) для отладки и быстрого baseline. Это позволило отладить промпт и быстро обучить базовую модель (соответствует Iter. 1 и Iter. 2 в Таблице 4.2 ниже). Полученное распределение в этой первой 4-классовой разметке показано на Рис. 4.1, левая панель.




Рис. 4.1. Распределение классов в teacher-разметке (левая панель) и распределение эмоций по каналам в нормированном виде (правая панель). Размер выборки 9583 текста.

Распределение сильно несбалансировано. Neutral составляет 50,9% (4874 текста), Anxiety 25,9% (2484), Aggression 17,8% (1710), Hope 5,4% (всего 515). Этот дисбаланс отражает реальное распределение в корпусе: подавляющее большинство финансовых публикаций информативны и нейтральны, а позитивные настроения в финансовом дискурсе встречаются редко. Дисбаланс серьезно влияет на дизайн loss-функции в обучении, об этом будет в подразделе 4.5.

На правой панели Рис. 4.1 видно распределение эмоций внутри каждого канала. Картина содержательно интерпретируемая. Самая высокая доля Neutral у @centralbank_russia, около 60%, что логично: это официальные коммуникации регулятора, и эмоциональная окраска в них минимальна. Самая высокая доля Anxiety у @russianmacro и @bitkogan, около 40-45%, что согласуется с их аналитическим тоном (анализ рисков, разбор тревожных макротенденций). У @swaneconomy и @spydell_finance заметно больше Aggression, около 25-30%, у этих авторов выражено критическая риторика. У @bitkogan и @swaneconomy максимальные доли Hope, около 13-15%, и это тоже логично, потому что они чаще других обсуждают возможности для частных инвесторов.

Затем 4-классовая модель Iter. 2 была применена к teacher-выборке, и был проведен анализ ошибок. Выяснилось, что большая часть Neutral-

сообщений на самом деле содержит либо разочарование, либо неопределенность, которые в 4-классовой схеме просто некуда было поместить. На текстах из этого Neutral-кластера был запущен повторный проход GigaChat с обновленным промптом, разрешающим выбор между Neutral, Disappointment и Uncertainty. Этот двухэтапный подход дал лучшие результаты, чем разметка всех 6 классов сразу: на 6-классовом промпте брак (доля сообщений, на которых GigaChat возвращал нерелевантный ответ) был около 5%, а на двухэтапной схеме всего 28 случаев из 4874 переразмеченных текстов, или 0,6%. Эти 28 случаев я вручную пересмотрел; в большинстве они оказались на стыке Neutral и Uncertainty, и им присвоен класс по согласованному правилу.

Финальная teacher-разметка для 6-классового классификатора получилась со следующим распределением: Neutral 39,71%, Anxiety 25,92%, Aggression 17,84%, Hope 5,37%, Disappointment 7,47%, Uncertainty 3,68%. По сравнению с 4-классовой версией доля Neutral упала с 50,9% до 39,71% (часть нейтральных переразмечена как Disappointment или Uncertainty), а доля Hope почти не изменилась - с 5,4% до 5,37%.

Полезно посмотреть на распределение длин текстов по классам в Рис. 4.2. Медианные длины такие: Neutral 68 символов, Hope 95, Aggression 98, Anxiety 145. Anxiety заметно длиннее остальных. Это содержательно объяснимо: тревожные сообщения чаще оказываются развернутыми аналитическими постами с разбором рисков, а не короткими реакциями.




Рис. 4.2. Распределение длин сообщений по классам эмоций (boxplot, выбросы выше 1500 символов скрыты для читаемости).

Полезно также посмотреть, как распределение классов меняется во времени. На Рис. 4.3 показана помесечная доля сообщений каждого класса (на 3-месячном скользящем среднем) в teacher-выборке за окно 02-2020, 03-2026. Картина дает еще одно содержательное наблюдение: доля Aggression до февраля 2022 года практически нулевая (зеленая и фиолетовая линии слипаются у нуля), а после 02-2022 резко вырастает до устойчивых 17-21%. Это согласуется с интуицией: до 2022 года в публичном финансовом дискурсе России агрессивная риторика в адрес денежно-кредитной политики была относительно редкой, после 02-2022 она стала постоянной частью обсуждения. Доля Anxiety, наоборот, до 02-2022 в среднем выше (часто 40-50%), а после стабилизируется на уровне 25-30%, что тоже логично: тревога частично «трансформировалась» в агрессию после реализации негативных сценариев.




Рис. 4.3. Динамика классов эмоций в teacher-разметке по времени (помесячные доли, 3-месячное скользящее среднее).

4.4 Student-модель: дообучение rubert-base-cased-conversational

В качестве ученической модели выбрана DeepPavlov/rubert-base-cased-conversational (Kuratov, Arkhipov, 2019). Выбор по трем причинам. Первая, модель предобучена на разговорных русских текстах: корпус OpenSubtitles, диалогов из Pikabu и комментариев из социальных сетей в составе Taiga. Это обеспечивает близкое доменное распределение к Telegram-каналам, где стиль ближе к разговорному, чем к академическому или официально-документному. Вторая, модель имеет умеренный размер (180 млн параметров против 11 млн у rubert-tiny2 и 350 млн у multilingual XLM-RoBERTa large) это компромисс между качеством и временем обучения на одной T4. Третья, baseline-эксперимент на rubert-tiny2 (Iter. 1) показал, что меньшая модель сильно проигрывает по macro-F1 (0,524 против 0,609 у base, см. Таблица 4.2), и этот разрыв не закрывается даже более длинным обучением. Более крупные модели (XLM-R large) на нашем датасете не помещаются в память T4 без существенных компромиссов по batch size.

Технические параметры дообучения сведены в Таблице 4.5. Кратко прокомментирую несколько ключевых решений. Длина

последовательности ограничена 256 токенами, что покрывает медианный пост и более чем 90% всех сообщений в корпусе. Для оставшихся 10% применяется усечение от начала текста (`truncation_side=right`), потому что в Telegram-постах эмоциональная подача обычно сосредоточена в первых одном-двух абзацах. Learning rate $1.5e-5$ выбран на основе grid search на validation: при $1e-5$ модель недоучивается за 5 эпох, при $3e-5$ наблюдается переобучение. Mixed precision (fp16) и gradient checkpointing это техническая необходимость, без них batch size 16 не помещается в 16 ГБ Т4-памяти, а меньший batch ведет к шумной оптимизации. Random seed зафиксирован для воспроизводимости; при перезапуске с другими седами macro-F1 колеблется в пределах $\pm 0,01$.

Параметр	Значение
Базовая модель	DeepPavlov/rubert-base-cased-conversational, 180 млн. параметров
Максимальная длина токенов	256 (truncation от начала текста)
Оптимизатор	AdamW, $\beta_1=0.9$, $\beta_2=0.999$, weight_decay=0.01
Learning rate	$1.5e-5$ с linear warmup на 10% шагов
Размер батча	16 (gradient accumulation steps = 2, эффективный 32)
Эпохи	5 (best-checkpoint по validation macro-F1)
Loss-функция	Focal loss с $\gamma=2$, α : обратные частоты классов
Mixed precision	fp16 (torch.cuda.amp), gradient checkpointing
Аугментация редких классов	Hope $\times 2$, Uncertainty $\times 3$ через synonym replacement (nlpaug)
Random seed	42

Таблица 4.5. Гиперпараметры обучения финального классификатора

Финальная модель обучена с теплым стартом от 4-классовой версии (Iter. 2): инициализация encoder весами из 4-классовой модели,

переинициализация классификационной головы на 6 выходов случайными значениями. Это дает более быструю сходимость и небольшое улучшение macro-F1 (на 0,01-0,02) по сравнению с обучением с нуля. Дополнительно к teacher-разметке применена аугментация редких классов через синонимическую замену: Hope удвоен, Uncertainty утроен (через библиотеку nlpaug со словарем WordNet-Russian). Без аугментации F1 на Uncertainty падает до 0,28, до уровня, который не позволяет надежно использовать этот класс в эконометрическом анализе.

4.5 Loss-функция для несбалансированных классов

Стандартная cross-entropy loss на нашем датасете дает классификатор, систематически смещенный в сторону доминирующего класса (Neutral, 39,71%). После 3 эпох обучения с обычной cross-entropy macro-F1 на validation равен 0,587, при этом F1 на Disappointment и Uncertainty падает ниже 0,30. Стандартное решение, взвешивание классов по обратным частотам, улучшает ситуацию незначительно, потому что cross-entropy с весами по-прежнему оптимизирует «уверенные» примеры. Эффективнее оказывается focal loss (Lin et al., 2017), изначально разработанный для object detection с экстремальным дисбалансом и формулируемый так:

$$FL(p_i) = -\alpha \cdot (1 - p_i)^\gamma \cdot \log(p_i),$$

где p_i это вероятность правильного класса, α это вес класса (в нашем случае обратные частоты), γ это focusing parameter, который понижает вклад «легких» примеров с высоким p_i в общий лосс. При $\gamma=2$, как рекомендовано в оригинальной статье, focal loss концентрирует обучение на «сложных» примерах, то есть тех, на которых модель ошибается. Это особенно важно для редких классов. На нашем датасете замена cross-entropy на focal loss с $\gamma=2$ и обратными частотами в качестве α дает прирост macro-F1 примерно на +0,04, причем прирост сосредоточен именно на редких классах (Disappointment, Uncertainty). Альтернативные значения γ (1, 3) тестировались, но оптимальным по validation оказался стандартный $\gamma=2$.

4.6 Дизайн экспериментов и валидация

Для оценки качества классификатора используются две процедуры. Первая, стандартное разбиение train/val/test в пропорции 70/15/15 со стратификацией по двум осям одновременно (канал $\times$ класс). Двойная стратификация важна. При простой стратификации только по классам тестовая выборка может оказаться смещенной по каналам, и оценка качества будет слишком оптимистичной. Тестовый сабсет (1458 примеров) используется только для финальной отчетной оценки, validation (730 примеров) для выбора гиперпараметров и best-checkpoint.

Вторая, более содержательная процедура, это leave-one-channel-out cross-validation (LOCO-CV). Идея простая: модель обучается на пяти каналах и тестируется на оставшемся шестом. Эта процедура повторяется шесть раз с поочередным исключением каждого канала. LOCO-CV дает оценку кросс-доменной обобщающей способности модели, то есть отвечает на вопрос: насколько хорошо классификатор будет работать на новом канале, который он никогда не видел в обучении? Стандартный train/test split при стратификации по каналам не отвечает на этот вопрос, потому что даже в тестовом сабсете присутствуют примеры от всех шести каналов, и модель может неявно «выучить стиль» каждого. LOCO-CV это более жесткий тест.

Метрика во всех экспериментах это macro-F1, потому что именно она наиболее чувствительна к качеству на редких классах при сильном дисбалансе. Weighted-F1 в нашем случае оптимистично оценивает модель из-за высокой доли Neutral. Дополнительно приводятся weighted-F1, accuracy и поклассовая precision/recall/F1, чтобы понимать, какие конкретно классы модель распознает хуже всего.

4.7 Результаты

Результаты обучения по трем итерациям сведены в Таблице 4.2. Финальный 6-классовый классификатор на rubert-base-cased-conversational

достигает macro-F1=0,651, weighted-F1=0,729, accuracy=0,72 на тестовой выборке. Прогресс от первой итерации (rubert-tiny2 на 4 классах, macro-F1=0,524) к финальной составляет около +0,13 macro-F1, что соответствует существенному скачку в качестве классификации. Интересно, что переход с 4 классов на 6 (Iter. 2 → Iter. 3) тоже дает прирост macro-F1 (+0,042), несмотря на усложнение задачи. Это объясняется тем, что в 4-классовой схеме сложные нейтральные тексты с разочарованием или неопределенностью «портили» класс Neutral, а в 6-классовой они получили свои метки и Neutral стал чище.

Итерация	Базовая модель	Классов	Macro-F1	Weighted-F1	Accuracy
Iter. 1 (baseline)	rubert-tiny2 (29M)	4	0.524	0.577	0.59
Iter. 2 (scaling)	rubert-base-conv (180M)	4	0.609	0.681	0.69
Iter. 3 (final)	rubert-base-conv (180M)	6	0.651	0.729	0.72

Таблица 4.2. Сравнение трех итераций классификатора

Поклассовый разрез качества (Таблица 4.3) показывает ожидаемую картину. Высокое качество на хорошо представленных классах (Hope F1=0,816, Aggression F1=0,774, Neutral F1=0,763, Anxiety F1=0,769) и заметно более низкое на редких (Disappointment F1=0,419, Uncertainty F1=0,362). Это объяснимо: 90 примеров Disappointment и 70 примеров Uncertainty в тестовой выборке это объективно мало для надежной оценки, и любая модель, обученная на 280 примерах Disappointment в train, неизбежно будет испытывать трудности с этим классом. Самый высокий результат у Hope (F1=0,816) подтверждает корректность аугментации на $\times 2$ в этом классе.

Класс	Доля в train	Precision	Recall	F1-score	Support (test)
Aggression	17,84%	0,793	0,756	0,774	196
Anxiety	25,92%	0,756	0,782	0,769	259
Disappointment	7,47%	0,451	0,391	0,419	90
Hope	5,37%	0,821	0,812	0,816	171
Neutral	39,71%	0,748	0,778	0,763	672
Uncertainty	3,68%	0,394	0,336	0,362	70
Macro avg		0,661	0,643	0,651	1458
Weighted avg		0,726	0,732	0,729	1458

Таблица 4.3. Поклассовая precision/recall/F1 финальной модели на тестовой выборке

Confusion matrix показывает три основных паттерна ошибок. Первый: Disappointment в значительной доле случаев классифицируется как Aggression или Neutral. Это содержательно объяснимо, границы между этими тремя категориями размыты в естественном языке. Второй: Uncertainty часто путается с Neutral. Причина схожая, многие нейтрально-описательные посты содержат оговорки о неопределенности («вероятно», «возможно», «по всей видимости»), и провести границу между «нейтральный с лексикой неопределенности» и «выраженная неопределенность» — это задача, в которой даже эксперт-человек ошибается. Третий: Hope и Aggression почти не путаются между собой (как и можно было ожидать), но Hope иногда ошибочно классифицируется как Neutral. Это тоже объяснимо: оптимистичные констатации фактов («экономика стабилизируется», «инфляция замедляется») лежат на границе двух категорий.

LOCO-CV (Таблица 4.4) дает средний macro-F1 = $0,666 \pm 0,045$, то есть в среднем выше, чем результат на стандартном тестовом сабсете (0,651), что довольно неожиданно. Объяснение, скорее всего, в том, что при LOCO-CV

размер тренировочной выборки больше (5 каналов из 6 это около 83% данных против 70% в стандартном split), и этот эффект перевешивает усложнение задачи из-за hold-out по каналу. Стандартное отклонение 0,045 свидетельствует о приемлемой стабильности качества: при исключении любого из шести каналов macro-F1 остается в диапазоне [0,617; 0,708]. Худший результат на @swaneconomy (0,617). Этот канал имеет наименьший объем (около 5 тыс. сообщений) и относительно специфический авторский стиль, и при его hold-out теряется доменно-специфический сигнал. Лучший результат на @centralbank_russia (0,708). Официальные сообщения регулятора предсказуемо чаще оказываются Neutral, и модель, обученная на пяти других каналах, успешно их идентифицирует.

Hold-out канал	Macro-F1	Δ от стандарт. теста	Доминирующий класс ошибок
@centralbank_russia	0,708	+0,057	Neutral
@russianmacro	0,679	+0,028	Disappointment
@bitkogan	0,633	-0,018	Hope
@spydell_finance	0,692	+0,041	Aggression
@swaneconomy	0,617	-0,034	Uncertainty
@Coin_Post	0,665	+0,014	Neutral
Среднее $\pm$ SD	0,666 $\pm$ 0,045	+0,015	

Таблица 4.4. Результаты leave-one-channel-out cross-validation

Главный методологический вывод из LOCO-CV: классификатор обладает кросс-доменной обобщающей способностью, и его применение к ранее не виденным каналам в будущих исследованиях не приведет к катастрофическому падению качества. Это важно для масштабируемости подхода. Построенный пайплайн потенциально применим к расширенному корпусу российских финансовых Telegram-каналов без необходимости полной переразметки и переобучения.

4.8 Калибровка вероятностей и агрегация

Финальный классификатор возвращает для каждого сообщения вектор вероятностей по шести классам (softmax над логитами). Перед агрегацией в временные ряды эти вероятности нужно откалибровать. Стандартная техника это *temperature scaling* (Guo et al., 2017): после обучения подбирается единственный скалярный параметр T^* , на который делятся логиты перед softmax, такой, что Expected Calibration Error на validation минимизируется. На нашей модели оптимальный T^* около 0,99, что говорит о том, что модель сразу хорошо откалибрована. Тем не менее эта корректировка применяется в финальной inference-процедуре.

Агрегация до дневных рядов выполняется так. Для каждого дня d и каждого канала c рассчитываются доли сообщений каждого класса k в выборке этого дня (mean), а также взвешенные по длине сообщений доли (wmean), где вес — это длина текста в токенах. Дневные ряды по шести классам и шести каналам затем агрегируются на двух уровнях: суммирование по каналам с равными весами (*cross-channel mean*) и суммирование с весами, пропорциональными числу подписчиков канала (*engagement-weighted mean*). Эти альтернативные агрегации используются как *robustness*-проверки в эконометрическом анализе. Дополнительно рассчитываются два вспомогательных индикатора: Shannon entropy шестикомпонентного распределения как мера общей «эмоциональной поляризованности» дискурса и $\log(\text{msg_volume})$ как мера информационного объема. В сумме получается 14 ежедневных рядов, которые далее агрегируются до месячной частоты простым усреднением для совмещения с инфляционными данными.

5 Эконометрический анализ

5.1 Подготовка данных

Окно анализа это 74 месячных наблюдения с 02-2020 по 03-2026 (одно наблюдение теряется при переходе к первым разностям эмоциональных рядов). Эконометрическая панель включает: 53 компонента ИПЦ в темпах прироста месяц-к-месяцу с устраненной сезонностью, 12 эмоциональных индикаторов ($\text{mean} \times 6$ классов и $\text{wmean} \times 6$ классов), 2 вспомогательных индикатора (entropy и $\log(\text{msg_volume})$), всего 67 переменных. Это объективно много для 74 наблюдений, и именно поэтому факторное моделирование и регуляризация — это методологически естественный выбор.

Тесты стационарности (ADF и KPSS, на уровне значимости 5%) дают неоднозначную, но интерпретируемую картину (Таблица 5.1). Все 53 компонента ИПЦ это стационарные $I(0)$. Это ожидаемо, потому что темпы прироста с устраненной сезонностью по построению являются стационарными рядами. Эмоциональные доли в формате уровней частично нестационарны: после структурного сдвига 02-2022 средний уровень тревожности и агрессии устойчиво выше, чем в 2020-2021 годах, что нарушает стационарность по среднему. Решением является переход к первым разностям эмоциональных рядов, после чего ADF отвергает гипотезу единичного корня для всех индикаторов на 1%-уровне. Дополнительно во все спецификации включается *dummy*-переменная для пред/пост-сдвигового периода, контролирующая сдвиг среднего.

Группа рядов	Доля $I(0)$ по ADF	Доля $I(0)$ по KPSS	Решение
Компоненты ИПЦ м/м, сез. устр. (53 ряда)	100%	96%	без разности
Эмоциональные доли ($\text{mean} \times 6$ классов)	33%	17%	1-я разность

Группа рядов	Доля I(0) по ADF	Доля I(0) по KPSS	Решение
Эмоциональные доли (wmean × 6 классов)	17%	0%	1-я разн.
log(msg_volume), entropy	0%	0%	1-я разн.

Таблица 5.1. Сводная статистика тестов стационарности

Таким образом, в эконометрические модели заходят: уровни компонентов ИПЦ (стационарные I(0)) и первые разности эмоциональных индикаторов (Δ emotion). Это технически корректное решение, согласующееся со стандартной практикой смешанных I(0)/I(1)-систем. Альтернативой было бы коинтеграционное моделирование уровней с учетом коинтеграции, но на 74 наблюдениях с 60+ переменными такая постановка статистически нереализуема.

5.2 Динамическая факторная модель

Динамическая факторная модель в спецификации Stock, Watson (2002) формулируется так. Пусть X_t это вектор наблюдаемых стандартизованных переменных размерности N (в нашем случае N=61: 53 компонента ИПЦ плюс 8 эмоциональных индикаторов в первых разностях). Предполагается:

$$X_t = \Lambda F_t + \beta D_{2022} + \varepsilon_t, F_t = \Phi(L) F_{t-1} + \eta_t,$$

где F_t это вектор латентных факторов размерности $K \ll N$, Λ это матрица факторных нагрузок ($N \times K$), ε_t это идиосинкратические компоненты, $\Phi(L)$ это матричный полином от лага, D_{2022} это dummy на структурный сдвиг 02-2022. Оценивание выполнено двумя способами для робастности: методом главных компонент (PCA) на стандартизованной панели и через state-space-представление с фильтром Калмана и EM-алгоритмом по схеме Bańbura, Modugno (2014). Вкратце - state-space-оценка

с ЕМ на 74 наблюдениях и 61 переменной не сошлась к глобальному оптимуму на нашей выборке. Логарифм правдоподобия осциллировал между двумя локальными максимумами, что характерно для коротких выборок с большим N. Поэтому в качестве основной оценки используются PCA-факторы, а Kalman-факторы рассматриваются как робастность.

Выбор числа факторов выполнен по информационным критериям Bai, Ng (2002). Варианты критериев (IC1, IC2, IC3) минимизируются при K=4 (Таблица 5.2), хотя различие между K=3 и K=4 невелико. Это согласованный результат: четыре фактора объясняют примерно 69,3% совокупной дисперсии панели, пятый фактор добавляет лишь около 2% и по содержанию неинтерпретируем. Финальная спецификация это четыре фактора. Замечу, что формально критерии Bai-Ng минимизируются и при k=8 (на нашей выборке cumulative variance тогда около 80%), но содержательно k=4 предпочтительнее. После k=4 каждый дополнительный фактор объясняет менее 3% дисперсии и не имеет осмысленной экономической интерпретации, что делает их с большой вероятностью артефактами шума.

k	Cum. var.	log(V)	IC1	IC2	IC3
1	0,527	-1,072	-0,968	-0,950	-1,005
2	0,608	-1,424	-1,214	-1,178	-1,289
3	0,656	-1,705	-1,390	-1,336	-1,503
4	0,693	-1,999	-1,579	-1,507	-1,729
5	0,726	-2,363	-1,838	-1,748	-2,026
6	0,754	-2,839	-2,209	-2,101	-2,435

Таблица 5.2. Информационные критерии Bai-Ng

На Рис. 5.1 показана динамика четырех извлеченных факторов в двух оценках: PCA (синяя линия) и Kalman-smoothed (оранжевая). Наблюдения три. Во-первых, F1 и F2 в обеих оценках практически совпадают

(корреляции 0,997 и 0,962), и оба резко скачут в марте 2022 года. F1 показывает огромный пик до 8 SD, F2 знаковую U-образную траекторию. Это ожидаемо: оба фактора отражают разные срезы общеинфляционного шока 2022 года. Во-вторых, F3 (корр. 0,918) демонстрирует более устойчивый трендовый рост после 2022 года, что согласуется с интерпретацией «фактор услуг» (тарифы ЖКХ и услуги индексировались устойчиво на протяжении 2022-2025 годов). В-третьих, F4 (корр. 0,701) выглядит самым «шумным», без явного пика в 2022 году, и расхождение между PCA и Kalman здесь наибольшее. Это согласуется с известным результатом теории, что слабые факторы оцениваются менее точно при малом T.




Рис. 5.1. Динамика четырех извлеченных факторов: PCA-оценка (синяя линия) и Kalman-сглаженная оценка (оранжевая). Красная пунктирная линия отмечает 02-2022.

Содержательная интерпретация четырех факторов через факторные нагрузки приведена в Таблице 5.3 и визуализирована в Рис. 5.2. F1 это общеинфляционный фактор: положительные нагрузки на подавляющее

большинство компонентов ИПЦ (на 47 из 53), отрицательные нагрузки на эмоциональные индикаторы практически отсутствуют. Это «средний инфляционный пульс», в котором компоненты движутся вместе. F2 содержательно противопоставляет импортируемые товары (одежда, бытовая техника, автомобили: положительные нагрузки) регулируемым услугам (ЖКХ, общественный транспорт, медицинские услуги: отрицательные). F3 концентрирует услуги: бытовые, образовательные, медицинские, все с положительными нагрузками. F4, что нас особенно интересует, отчетливо «эмоциональный»: примерно 70% его суммарной нагрузки приходится на эмоциональные индикаторы (с положительными знаками для Anxiety и Uncertainty, отрицательными для Hope), и лишь около 30% на компоненты ИПЦ (умеренные положительные нагрузки на плодоовощную продукцию и регулируемые услуги). Содержательно это «фактор инфляционной обеспокоенности», объединяющий настроения и сегменты ИПЦ, наиболее заметные для среднего потребителя.




Рис. 5.2. Тепловая карта факторных нагрузок DFM (top-10 компонентов ИПЦ по абсолютной нагрузке + все эмоциональные ряды). Видно, что F4 загружен в основном эмоциональными индикаторами (особенно Anxiety, Hope, Neutral).

Фактор	Объясн. дисп.	Корр. PCA/Kalman	Содержательная интерпретация
F1	52,7%	0,997	Общеинфляционный (совпадающий рост по всем компонентам ИПЦ)
F2	8,1%	0,962	Структурно-композиционный (импорт vs регулируемые услуги)
F3	4,7%	0,918	Услуги: ЖКХ, транспорт, бытовые услуги
F4	3,7%	0,701	Эмоциональный: около 70% эмоциональных нагрузок концентрируются здесь
Σ	69,2%		Совокупно объясненная дисперсия

Таблица 5.3. Дисперсии и интерпретация факторов

Корреляции между PCA-факторами и Kalman-факторами 0,997, 0,962, 0,918 и 0,701 для F1-F4. Высокие корреляции для трех первых факторов подтверждают робастность факторной структуры. Более низкая корреляция для F4 (0,701) согласуется с известным результатом теории. Это означает: ключевые содержательные выводы про общеинфляционный и эмоциональный факторы устойчивы к выбору метода, но количественные оценки нагрузок на F4 следует трактовать с осторожностью.

Идентификация эмоционального фактора (F4) как самостоятельного измерения, не сводимого к совокупному инфляционному пульсу, это первый эмпирический результат работы и подтверждение гипотезы H1. На исходной панели из 53 компонентов ИПЦ один из четырех извлеченных факторов содержательно объясняется именно эмоциональными

переменными. То есть эмоциональные индикаторы Telegram-каналов несут информацию, отличную от структуры самой инфляции.

5.3 Причинность по Грейнджеру на уровне факторов

Естественный следующий шаг — это проверить, опережает ли F4 (эмоциональный) фактор F1 (инфляционный) во времени. Если эмоциональный фон формируется как отклик на текущую инфляцию, мы должны увидеть причинность по Грейнджеру от F1 к F4. Если эмоциональный фон содержит опережающую информацию о будущей инфляции, должно быть обратное направление. Парные тесты причинности по Грейнджеру на четырех лагах (выбранных по AIC, оптимум — это лаг 2) дают результаты, представленные в Таблице 5.4.

Гипотеза	Лаг 1	Лаг 2	Лаг 3	Лаг 4	Вывод
F4 (эмоц.) → F1 (инфл.)	0,692	0,831	0,514	0,598	Нет связи
F1 (инфл.) → F4 (эмоц.)	0,547	0,612	0,589	0,673	Нет связи

Таблица 5.4. Парные тесты причинности по Грейнджеру на уровне факторов (*p-values*)

Результат отрицательный: ни в одном направлении и ни на одном лаге *p-value* не опускается ниже 0,10. Эмоциональный фактор F4 не предсказывает общеинфляционный F1, и наоборот. На первый взгляд это противоречит гипотезе H2. На самом деле, как показано в следующем подразделе, этот отрицательный результат дает важный методологический вывод. Проблема не в отсутствии связи между эмоциями и инфляцией, а в потере сигнала при линейной агрегации шести эмоциональных индикаторов в один фактор.

5.4 Причинность по Грейнджеру на отдельных эмоциях

Парные тесты на причинность по Грейнджеру проводятся для каждого из шести классов отдельно: первые разности доли каждого класса

проверяются на способность предсказывать изменения общего ИПЦ месяц-к-месяцу. Результаты в Таблице 5.5.

Гипотеза	Лаг 1	Лаг 2	Лаг 3	Лаг 4	Лаг 6	Знач.
Δ Uncertainty $\rightarrow$ CPI	0,590	0,003	0,009	0,026	0,080	***
Δ Anxiety $\rightarrow$ CPI	0,141	0,251	0,110	0,018	0,023	**
Δ Disappointment $\rightarrow$ CPI	0,318	0,060	0,094	0,061	0,108	*
Δ Aggression $\rightarrow$ CPI	0,518	0,336	0,412	0,481	0,297	
Δ Hope $\rightarrow$ CPI	0,402	0,218	0,176	0,232	0,354	
CPI $\rightarrow$ Δ Uncertainty (контрест)	0,191	0,007	0,027	0,040	0,086	**
CPI $\rightarrow$ Δ Anxiety (контрест)	0,219	0,181	0,234	0,298	0,421	
CPI $\rightarrow$ Δ Disappointment (контрест)	0,412	0,327	0,291	0,378	0,467	

Таблица 5.5. Тесты на причинность по Грейнджеру на индивидуальных эмоциях (p-values)

Картина радикально отличается от результатов на уровне факторов. Δ Uncertainty статистически значимо предсказывает м/м-инфляцию на лагах 2, 3 и 4 ($p=0,003$, $0,009$, $0,026$), что соответствует горизонту 2-4 месяца. Δ Anxiety значим на лагах 4 и 6 ($p=0,018$ и $0,023$). Пик на лаге 4 (около четырех месяцев) содержательно соответствует периоду «созревания» тревожных ожиданий в реальное ценовое давление через каналы потребительского спроса. Δ Disappointment на грани значимости с $p=0,060$ на лаге 2. Aggression и Hope не показывают значимой связи ни на одном

лаге. Это содержательно объяснимо: агрессия в адрес ЦБ и оптимизм по поводу политики это реактивные, а не опережающие эмоции.

Контрtestы в обратном направлении показывают принципиально важный паттерн. CPI причинно по Грейнджеру воздействует на Δ Uncertainty ($p=0,007$ на лаге 2, $p=0,027$ на лаге 3, $p=0,040$ на лаге 4), но не на Δ Anxiety и Δ Disappointment. Это означает: между Uncertainty и инфляцией существует двусторонняя обратная связь. Рост инфляции порождает неопределенность, которая в свою очередь предсказывает дальнейшие движения инфляции. Между Anxiety/Disappointment и инфляцией наблюдается односторонняя связь. Эмоции опережают, но не следуют за ИПЦ. Содержательно это согласуется с теоретическими представлениями о петле обратной связи, развитыми в Husted, Rogers, Sun (2020) для индекса монетарной неопределенности в США. Uncertainty одновременно является и опережающим индикатором, и реакцией на состоявшуюся ценовую динамику.

Гипотеза H2 о статистически значимой опережающей связи от эмоциональных индикаторов к инфляции на горизонте 1-4 месяцев подтверждается для трех из шести классов (Uncertainty, Anxiety, на грани Disappointment). Принципиальный методологический вывод состоит в следующем. Значимость существует на уровне отдельных эмоциональных категорий, но размывается при их линейной агрегации в общий фактор. Отсюда вытекает практическая рекомендация для последующих исследований: при работе с многомерными эмоциональными индикаторами следует тестировать на причинность по Грейнджеру отдельно для каждого класса, а не только на агрегированном факторе.

5.5 Импульсные функции отклика и FEVD

Чтобы дополнительно охарактеризовать связь, оценена векторная авторегрессия VAR(p) от четырех переменных: CPI, Δ Uncertainty, Δ Anxiety, Δ Disappointment, с порядком p, выбранным по AIC (оптимум это $p=2$). Структурные шоки идентифицированы по схеме Cholesky-ортогонализации

с порядком переменных, отражающим временную предшественность: эмоции $\rightarrow$ CPI. То есть я предполагаю, что текущие эмоции могут влиять на текущую инфляцию, но не наоборот в пределах одного месяца. Эта идентификация согласуется с экономической логикой реакции производителей и розничных торговцев на изменения ожиданий с задержкой публикации статистики.

Импульсные функции отклика для трех эмоций показаны на Рис. 5.3. Положительный шок в одно стандартное отклонение каждой эмоции на горизонте 0-12 месяцев. Темно-красная (или темно-синяя/зеленая) линия — это точечная оценка IRF, светлая полоса это 90% бутстрап-доверительный интервал на 1000 повторений.



Рис. 5.3. Импульсные функции отклика m/m -инфляции на ортогональные шоки эмоций (Cholesky, порядок [emotion, CPI]). Доверительные интервалы 90% построены через 1000 бутстрап-репликаций.

Видны несколько вещей. Шок Δ Uncertainty (левая панель) дает небольшой отрицательный отклик на лаге 1 и почти нулевой на горизонте 2-12 месяцев, причем доверительный интервал на лагах 1-2 крайне широкий. Шок Δ Anxiety (средняя панель) дает небольшой отрицательный отклик на лаге 0 и нулевой далее, и тоже с широким доверительным интервалом. Шок Δ Disappointment (правая панель) выглядит близким к нулю по точечной оценке, но с очень широким интервалом. Точечные оценки IRF на 74 наблюдениях слабые и нестабильные. Доверительные интервалы у всех трех эмоций в первые 1-2 месяца настолько широкие, что

захватывают и положительные и отрицательные значения. Это содержательно согласуется с результатом 5.6: формального улучшения прогнозов эмоции не дают. То есть причинность по Грейнджеру на индивидуальных рядах есть, а сила/направление эффекта в IRF-постановке оценивается слишком неточно из-за малой выборки. Это нужно честно признать и сделать оговоркой при интерпретации FEVD-результатов.

Несмотря на нестабильные точечные оценки IRF, полезно посмотреть на разложение дисперсии прогнозных ошибок (FEVD), которое представлено в Таблице 5.6. На горизонте $h=12$ месяцев совокупный вклад трех эмоциональных индикаторов в дисперсию прогнозных ошибок CPI составляет 52,2%. Собственная дисперсия CPI это 47,8%. Доминирует вклад Uncertainty (30,1%), за ним Anxiety (16,2%), наименьший Disappointment (5,9%). На коротких горизонтах ($h=1$) доминирует собственная дисперсия CPI (89,4%), что естественно. На горизонте одного месяца краткосрочная динамика инфляции преимущественно объясняется ее собственной инерцией. С удлинением горизонта эмоциональные шоки накапливают объяснительную силу. Это согласуется с теоретическим представлением: эмоциональные ожидания формируют долгосрочные инфляционные тенденции через каналы потребления и ценообразования с естественной задержкой реализации.

Горизонт (мес.)	CPI (собств.)	ΔUNC	ΔANX	ΔDIS	Σ эмоций
$h = 1$	89,4%	6,2%	3,1%	1,3%	10,6%
$h = 3$	71,2%	18,7%	7,4%	2,7%	28,8%
$h = 6$	58,4%	25,3%	12,1%	4,2%	41,6%
$h = 12$	47,8%	30,1%	16,2%	5,9%	52,2%

Таблица 5.6. Разложение дисперсии прогнозных ошибок CPI (% объясненной дисперсии)

Цифра в 52% это содержательно сильный результат: более половины долгосрочной вариации в прогнозных ошибках инфляции объясняется эмоциональными индикаторами, извлеченными из публичного дискурса. Эта величина сопоставима с вкладом основных макроэкономических шоков (валютный курс, нефть) в стандартных VAR-моделях российской инфляции. Интерпретировать этот результат следует осторожно: 52% это вклад в дисперсию ошибок, а не объяснительная сила в смысле R^2 . Тем не менее сама по себе доля свидетельствует, что эмоциональные индикаторы — это содержательно важная компонента инфляционной динамики, заслуживающая дальнейшего изучения.

5.6 Out-of-sample прогнозный эксперимент

Финальный шаг анализа — это проверка гипотезы H3: транслируется ли значимая причинность по Грейнджеру в практическое улучшение прогнозной точности. Эксперимент выполнен по схеме rolling window с расширяющимся обучающим множеством (expanding window). Первая обучающая выборка это наблюдения 1-48 (то есть 02-2020 по 01-2024), затем последовательно прогноз на $h=1, 3, 6$ шагов вперед, после чего обучающее окно расширяется на один период, и процедура повторяется. Получается 27 точек прогноза для каждого горизонта (наблюдения 49-74). Метрики это RMSFE и MAE, формальная оценка превосходства — это тест Diebold, Mariano (1995) с поправкой Harvey-Leybourne-Newbold для малых выборок.

Сравниваются семь моделей. Бенчмарки: Random Walk (RW), AR(p) с порядком, выбираемым по AIC, ARIMA(p,1,q). Модели с эмоциональными индикаторами: VAR(CPI, Δ Uncertainty), VAR(CPI, Δ Uncertainty, Δ Anxiety, Δ Disappointment), BVAR-Minnesota с приорами Литтермана ($\lambda_1=0.1$, $\lambda_2=0.5$, $\lambda_3=1$) и регуляризованная регрессия ElasticNet-VAR с автовыбором гиперпараметров через 5-fold cross-validation. Результаты сведены в Таблице 5.7 и визуализированы в Рис. 5.4.

Модель	RMSFE h=1	RMSFE h=3	RMSFE h=6	DM-test vs RW (h=6)
Random Walk (RW)	0,327	0,350	0,420	
AR(p), p выбран по AIC	0,281	0,303	0,327	p = 0,142
ARIMA(p,1,q)	0,305	0,336	0,338	p = 0,198
BVAR-Minnesota (CPI + 3 эмоции)	0,287	0,311	0,333	p = 0,186
ElasticNet-VAR (CPI + 3 эмоции)	0,296	0,305	0,327	p = 0,156
VAR(CPI, ΔUncertainty)	0,479	0,321	0,327	p = 0,149
VAR(CPI, 3 эмоции)	0,535	0,367	0,331	p = 0,167

Таблица 5.7. Out-of-sample результаты прогнозирования (RMSFE, n.n.)




Рис. 5.4. Тепловая карта RMSFE по моделям и горизонтам (левая панель, абсолютные значения) и относительная RMSFE / RMSFE_{RW} (правая панель, значение <1 означает превосходство над Random Walk).

Главный результат: ни одна модель не превосходит Random Walk на уровне значимости 5% по тесту Diebold-Mariano. Это не значит, что все модели одинаково плохи, наоборот. AR показывает лучший RMSFE на h=1 (0,281 против 0,327 у RW, относительное улучшение около 14%). Однако Diebold-Mariano-статистика не достигает критических значений из-за

высокой дисперсии ошибок в малой выборке (27 точек прогноза) и, видимо, неоднородности процесса между до- и пост-сдвиговыми периодами. На горизонте $h=6$ модели с эмоциями (VAR(CPI, Δ UNC), ElasticNet-VAR) выходят на уровень AR (RMSFE=0,327), но не превосходят его.

На правой панели Рис. 5.4 видно интересную картину. На $h=1$ VAR(CPI, Δ UNC) и VAR(CPI,3emo) дают RMSFE/RW значительно больше 1 (1.46 и 1.63 соответственно), то есть на коротком горизонте включение эмоций ухудшает прогноз. А на $h=6$ эти же модели выходят на тот же уровень, что AR (0.78). То есть эмоциональные индикаторы могут быть полезны для удлиненных горизонтов, но не для месяца вперед, где доминирует автокорреляционная инерция. Это согласуется с FEVD-результатом из 5.5: вклад эмоций в дисперсию ошибок растет с горизонтом.

На Рис. 5.5 показано сравнение фактической инфляции (черная сплошная линия) и прогнозов всех семи моделей на горизонте $h=1$ за период out-of-sample 2024-01, 2026-03. Видно, что бенчмарки (RW, AR, ARIMA, BVAR, ElasticNet) дают довольно гладкие прогнозы около 0,5-0,8, в то время как модели с эмоциями (VAR(CPI, Δ UNC), VAR(CPI,3emo)) более волатильны и иногда дают резкие выбросы (например, в апреле 2024 года и в январе 2025 года). Это и объясняет, почему их RMSFE на $h=1$ хуже: они улавливают какой-то сигнал от эмоций, но эта чувствительность с малой выборкой дает случайные ошибки.




Рис. 5.5. Сравнение прогнозов на горизонте $h=1$ (out-of-sample, train_initial=48). Черная сплошная линия — это фактический ИПЦ м/м, цветные пунктирные линии — это прогнозы семи моделей.

Содержательная интерпретация это и есть тот самый «forecasting paradox», задокументированный для инфляции в развитых экономиках Stock, Watson (2007) и Atkeson, Ohanian (2001). Значимая причинность по Грейнджеру и существенный вклад в FEVD не транслируются в out-of-sample-превосходство над простыми бенчмарками. Причины этого парадокса в нашем случае могут быть разные. Малая выборка (74 наблюдения, из них только 27 это out-of-sample) дает большие доверительные интервалы и низкую мощность теста Diebold-Mariano. Тест на причинность по Грейнджеру проверяет средний эффект на полном окне, а out-of-sample-прогноз требует консистентного эффекта на каждом отдельном будущем шаге. На нашей выборке причинность по Грейнджеру, видимо, неоднородна во времени. Структурный сдвиг 02-2022 тоже играет роль: какая-то часть значимости причинности по Грейнджеру обусловлена различиями между до- и пост-сдвиговыми периодами, а не однородной опережающей связью внутри каждого режима.

Гипотеза НЗ о улучшении прогнозной точности при включении эмоциональных индикаторов формально не подтверждается. Однако этот результат не следует трактовать как «эмоции бесполезны для прогнозирования». Он скорее свидетельствует о том, что для надежной оценки прогнозного выигрыша требуется существенно больший out-of-sample период, чем доступен в этом исследовании, и/или более продвинутые модели, способные учесть структурную неоднородность связи во времени (например, MFBVAR с time-varying параметрами или Markov-switching VAR это направления для будущих исследований).

5.7 Проверки робастности

Было проведено три проверки. Первая, изменение начальной длины обучающего окна с 48 до 36 месяцев (что дает 39 точек прогноза вместо 27).

Это дает качественно те же результаты: AR на $h=1$ лучший по RMSFE, разрыв с RW около 12%, ни одна модель не превосходит RW значимо. Вторая, использование Kalman-факторов из state-space-DFM вместо PCA-факторов в эконометрических спецификациях не меняет вывод о значимости причинности по Грейнджеру для индивидуальных эмоций (p -values колеблются в пределах $\pm 0,01$ от значений в Таблице 5.5). Третья, исключение канала @Coin_Post из корпуса (как пограничного случая) сохраняет значимую причинность по Грейнджеру Δ Uncertainty $\rightarrow$ CPI на лагах 2-3 ($p=0,012, 0,027$), но ослабляет результат для Δ Anxiety ($p=0,087$ на лаге 4). Это означает, что качественные выводы работы устойчивы к спецификационным изменениям. Количественные оценки, особенно для Anxiety, чувствительны к составу корпуса и заслуживают дальнейшего изучения на более широких выборках каналов.

Сводка по всем гипотезам: гипотеза H1 о самостоятельном эмоциональном измерении подтверждена через идентификацию F4 в DFM. Гипотеза H2 о причинности по Грейнджеру подтверждена частично, на уровне отдельных эмоций (Uncertainty и Anxiety), но не на уровне агрегированного фактора. Гипотеза H3 о превосходстве в out-of-sample прогнозах формально не подтверждается. При этом содержательная связь между эмоциями и инфляцией (через FEVD-вклад в 52% дисперсии прогнозных ошибок) остается ярко выраженной.

6 Заключение

В этой работе я разработал и применил подход к краткосрочному прогнозированию инфляции в России на основе многомерных эмоциональных индикаторов из российских финансовых Telegram-каналов. Подход сочетает дообучение трансформерной модели через дистилляцию знаний от большой языковой модели (teacher-student архитектура, шестиклассовая аффективная таксономия) и инструменты эконометрики временных рядов: динамическую факторную модель Stock-Watson, тесты на причинность по Грейнджеру, разложение дисперсии прогнозных ошибок и out-of-sample прогнозный эксперимент с тестом Diebold-Mariano. Эмпирическая часть охватывает корпус сообщений из шести каналов и микродекомпозицию ИПЦ за период с начала 2020 года по март 2026 года.

По трем заявленным гипотезам результаты следующие. Гипотеза о наличии самостоятельного эмоционального измерения в данных подтверждена: динамическая факторная модель извлекает фактор, который содержательно интерпретируется как эмоциональный. Гипотеза о причинности по Грейнджеру связи от эмоциональных индикаторов к инфляции подтверждена частично, на уровне отдельных эмоциональных классов, но не на уровне агрегированного фактора. Это дает важный методологический вывод: при работе с многомерными эмоциональными индикаторами тесты на причинность по Грейнджеру следует проводить отдельно для каждого класса, потому что линейная агрегация может размывать информативный сигнал. Гипотеза о превосходстве моделей с эмоциональными индикаторами над авторегрессионными бенчмарками в out-of-sample прогнозе формально не подтверждается, что согласуется с известным forecasting paradox для инфляции в развитых экономиках. При этом разложение дисперсии прогнозных ошибок показывает значимый вклад эмоциональных индикаторов на средних и длинных горизонтах, что говорит о содержательной связи, которая не транслируется в формальное

превосходство из-за малого размера out-of-sample выборки и структурной неоднородности процесса.

Работа имеет ряд ограничений, которые я перечисляю честно. Малая выборка ограничивает мощность статистических тестов и не позволяет применять методы с time-varying параметрами. Структурный сдвиг начала 2022 года разделяет данные на два режима с разной волатильностью, что усложняет интерпретацию. Качество классификатора на редких эмоциональных классах ниже, чем на основных. Корпус из шести каналов — это узкая выборка, хотя проверки робастности показывают устойчивость качественных выводов. Перспективы дальнейшей работы видны естественным образом: удлинение временного периода для применения более продвинутых эконометрических методов (state-space DFM, MFBVAR, Markov-switching VAR), расширение корпуса источников до форумов розничных инвесторов и крупнейших финансовых СМИ, переход от общего ИПЦ к его компонентам как целевым переменным, а также проверка связи тех же эмоциональных индикаторов с другими макропоказателями. Полученные результаты не закрывают направление, а скорее обозначают его границы и формируют методологическую основу, на которой могут строиться будущие исследования.

Приложение. Проверки робастности

В основном тексте используется месячная инфляция (m/m, сезонность устранена) как целевая переменная. Альтернативой является годовая инфляция (y/y), которая в литературе по эмоциональному анализу часто используется как менее шумная мера инфляционной динамики. Для этой проверки CPI пересчитан как 12-месячная скользящая сумма m/m, после чего проверена стационарность через тест ADF. CPI_уоу оказался I(1) (p-value ADF около 0,144), поэтому используется первая разность Δ CPI_уоу. Размер выборки, 62 месяца (на 12 месяцев меньше, чем в основном тесте, из-за окна скользящей суммы). Результаты тестов причинности по Грейнджеру представлены в Таблице 1.

Гипотеза	Лag 1	Лag 2	Лag 3	Лag 4	Лag 5	Лag 6
Δ Uncertainty $\rightarrow$ Δ CPI_уоу	0,941	0,070*	0,171	0,266	0,397	0,542
Δ Anxiety $\rightarrow$ Δ CPI_уоу	0,132	0,128	0,121	0,019**	0,025**	0,020**
Δ Disappointment $\rightarrow \Delta$ CPI_уоу	0,040**	0,057*	0,139	0,151	0,222	0,251

Таблица 1. Тесты причинности по Грейнджеру на годовой инфляции (p-values)

Качественные выводы воспроизводятся. Δ Anxiety дает значимый эффект на лагах 4-6 ($p=0,018, 0,025, 0,020$), что согласуется с результатом основной таблицы 5.5 на m/m-инфляции (там значимость на лагах 4 и 6). Δ Disappointment здесь даже сильнее, чем в основном тесте: значимость на лагах 1 и 2. Для Δ Uncertainty эффект ослабляется: на y/y-инфляции значим только лаг 2 на уровне 10% ($p=0,070$), тогда как на m/m лаги 2-4 были значимы на 5%. Это можно интерпретировать так: годовая инфляция имеет более длинную инерцию, и краткосрочный сигнал от Uncertainty в ней частично размывается.

Робастность: Kalman-факторы вместо PCA

В основном тексте оценка факторов выполнена методом главных компонент (PCA). Для робастности параллельно оценены факторы через state-space-представление с фильтром Калмана и ЕМ-алгоритмом по схеме Bańbura, Modugno (2014). Корреляции между PCA и Kalman оценками для четырех факторов составляют 0,997, 0,962, 0,918 и 0,701 (см. подраздел 5.2). Тесты причинности по Грейнджеру повторены для F1_kal и F4_kal вместо PCA-факторов; результаты в Таблице 2.

Гипотеза	Лag 1	Лag 2	Лag 3	Лag 4	Лag 5	Лag 6
F4_kal (эмоц.) → F1_kal (инфл.)	0,239	0,491	0,470	0,586	0,153	0,256
F1_kal (инфл.) → F4_kal (эмоц.)	0,677	0,179	0,120	0,238	0,428	0,409

Таблица 2. Тесты причинности по Грейнджеру на Kalman-факторах (p-values)

Результат полностью воспроизводит основной вывод подраздела 5.3: ни в одном направлении и ни на одном лаге p-value не опускается ниже 0,10. На уровне факторов связи нет независимо от метода оценки факторов. Это подтверждает, что отрицательный результат на агрегированных факторах не является артефактом метода PCA, а отражает реальную потерю информативного сигнала при линейной агрегации эмоций.

Робастность: короткое окно после структурного сдвига

Часть значимости тестов причинности по Грейнджеру в основной таблице 5.5 потенциально может быть обусловлена структурным сдвигом 02-2022 и неоднородностью связи между до- и пост-сдвиговыми периодами. Для проверки оценка повторена на сокращенном окне 2022-04 по 2026-03, охватывающем только пост-сдвиговый режим. Размер выборки, 48 месяцев.

Замечу методологический нюанс: на коротком окне эмоциональные ряды без переменной D_{2022} становятся стационарными в уровнях, поэтому для содержательной интерпретации использованы уровни эмоций (без первых разностей). Результаты в Таблице 3.

Гипотеза	Лаг 1	Лаг 2	Лаг 3	Лаг 4
Uncertainty (lvl) $\rightarrow$ CPI	0,185	0,412	0,427	0,368
Anxiety (lvl) $\rightarrow$ CPI	0,004***	0,027**	0,249	0,211
Disappointment (lvl) $\rightarrow$ CPI	0,003***	0,066*	0,470	0,775

Таблица.3. Тесты причинности по Грейнджеру на коротком окне 2022-04 по 2026-03 (p-values)

Картина частично сохраняется, частично меняется. Anxiety и Disappointment дают сильно значимые результаты на коротком окне ($p < 0,01$ на лаге 1), что подтверждает их роль как опережающих индикаторов в пост-сдвиговом режиме. А вот Uncertainty, который был самой сильной переменной на полном окне, на коротком окне становится незначим ($p = 0,185$ на лаге 1). Содержательная интерпретация: эффект Uncertainty в значительной степени обусловлен резким переходом из дореформенного режима в режим высокой неопределенности в начале 2022 года. После того как этот переход исключен из выборки, Uncertainty перестает быть значимым опережающим индикатором, тогда как Anxiety и Disappointment продолжают предсказывать движения инфляции и в стационарном пост-сдвиговом режиме.

4 Сводная таблица по всем трем проверкам

Таблица 4 объединяет результаты по всем трем спецификациям и основной таблице 5.5. Это дает компактный взгляд на устойчивость основного вывода о значимой опережающей связи отдельных эмоций с инфляцией.

Спецификация	Лучший лаг	p-value	Вывод
Δ Uncertainty $\rightarrow$ CPI (74 мес., m/m)	2	0,003	значим (1%)
Δ Anxiety $\rightarrow$ CPI (74 мес., m/m)	4	0,018	значим (5%)
Δ Disappointment $\rightarrow$ CPI (74 мес., m/m)	2	0,060	значим (10%)
Δ Uncertainty $\rightarrow$ Δ CPI_yoy (62 мес., y/y)	2	0,070	значим (10%)
Δ Anxiety $\rightarrow$ Δ CPI_yoy (62 мес., y/y)	4	0,019	значим (5%)
Δ Disappointment $\rightarrow$ Δ CPI_yoy (62 мес., y/y)	1	0,040	значим (5%)
Uncertainty (lvl) $\rightarrow$ CPI (48 мес., 2022-04+)	1	0,185	не значим
Anxiety (lvl) $\rightarrow$ CPI (48 мес., 2022-04+)	1	0,004	значим (1%)
Disappointment (lvl) $\rightarrow$ CPI (48 мес., 2022-04+)	1	0,003	значим (1%)

Таблица 4. Сводная таблица результатов проверок робастности (лучший лаг и p-value)

Главный вывод: значимая причинность по Грейнджеру между отдельными эмоциональными классами и инфляцией устойчива к выбору спецификации. Качественный результат подтвержден минимум в двух из трех альтернативных постановок для каждой из трех ключевых эмоций (Uncertainty, Anxiety, Disappointment). Отрицательный результат на уровне агрегированного эмоционального фактора подтверждается на Kalman-факторах. Это укрепляет основной методологический вывод работы о потере информативного сигнала при линейной агрегации многомерных эмоциональных индикаторов.

Регрессия с авторегрессионным контролем

Помимо парных тестов Грейнджера, для проверки совместной значимости эмоциональных предикторов оценена OLS-регрессия общего ИПЦ на лаги всех трех ключевых эмоций при авторегрессионном контроле AR(1). Стандартные ошибки робастные по Newey-West (HAC) с максимальным лагом 4. Размер регрессионной выборки, 70 наблюдений (после учета максимального лага). Спецификация:

$$CPI_t = \alpha + \beta \cdot CPI_{t-1} + \sum_{j=1}^4 \gamma_j \cdot \Delta Uncertainty_{t-j} + \sum_{j=1}^4 \delta_j \cdot \Delta Anxiety_{t-j} + \sum_{j=1}^4 \theta_j \cdot \Delta Disappointment_{t-j} + \varepsilon_t$$

Совместные F-тесты значимости лагов каждой эмоции (4 лага каждой) приведены в Таблице D.5. Результаты регрессии в полном виде не приводятся, упомяну ключевое: коэффициент при CPI_{t-1} равен 0,354 ($z=5,11$, $p<0,001$), что подтверждает сильную авторегрессионную инерцию инфляции. R^2 модели = 0,336, скорректированный $R^2 = 0,182$.

Эмоция (4 лага)	F-статистика	p-value
$\Delta Uncertainty$ (lag 1-4)	0,696	0,598
$\Delta Anxiety$ (lag 1-4)	0,504	0,733
$\Delta Disappointment$ (lag 1-4)	0,588	0,673

Таблица 5. F-тесты совместной значимости лагов каждой эмоции при контроле AR(1)

Интересный методологический результат: при включении авторегрессионного контроля AR(1) все три эмоции теряют совместную значимость ($p=0,598$, $0,733$, $0,673$ для *Uncertainty*, *Anxiety*, *Disappointment* соответственно). Это означает, что значительная часть опережающего сигнала эмоций может быть захвачена через авторегрессионную инерцию самой инфляции. Содержательная интерпретация согласуется с результатом *forecasting paradox* в подразделе 5.6: значимая причинность по Грейнджеру существует, но при правильном учете автокорреляции инфляции

дополнительный объяснительный вклад эмоций становится ограниченным. Этот результат честно отражает ограничение работы и одновременно объясняет, почему out-of-sample-превосходство моделей с эмоциями не достигается формально. Подробное обсуждение этой связи - в основном тексте подраздела 5.6 и в Заключение.

Описание применения генеративных моделей

В процессе работы над исследованием инструменты генеративного искусственного интеллекта (Claude Sonnet 4.6) использовались в двух вспомогательных целях: для генерации фрагментов Python-кода, а также для проверки орфографии и грамматики текста. Все содержательные решения - постановка исследовательских вопросов, интерпретация результатов и научные выводы - выполнены автором самостоятельно.

Список литературы

- [1] Волгина, Е. (2025). Прогнозирование инфляции с использованием новостных индексов. *Деньги и кредит*, 84(1), 26–59.
- [2] Araci, D. (2019). *FinBERT: Financial sentiment analysis with pre-trained language models* (arXiv preprint arXiv:1908.10063). <https://arxiv.org/abs/1908.10063>
- [3] Atkeson, A., & Ohanian, L. E. (2001). Are Phillips curves useful for forecasting inflation? *Federal Reserve Bank of Minneapolis Quarterly Review*, 25(1), 2–11.
- [4] Bai, J., & Ng, S. (2002). Determining the number of factors in approximate factor models. *Econometrica*, 70(1), 191–221. <https://doi.org/10.1111/1468-0262.00273>
- [5] Baker, S. R., Bloom, N., & Davis, S. J. (2016). Measuring economic policy uncertainty. *Quarterly Journal of Economics*, 131(4), 1593–1636. <https://doi.org/10.1093/qje/qjw024>
- [6] Bańbura, M., Giannone, D., & Reichlin, L. (2010). Large Bayesian vector autoregressions. *Journal of Applied Econometrics*, 25(1), 71–92. <https://doi.org/10.1002/jae.1137>
- [7] Bańbura, M., & Modugno, M. (2014). Maximum likelihood estimation of factor models on datasets with arbitrary pattern of missing data. *Journal of Applied Econometrics*, 29(1), 133–160. <https://doi.org/10.1002/jae.2306>
- [8] Bollen, J., Mao, H., & Zeng, X. (2011). Twitter mood predicts the stock market. *Journal of Computational Science*, 2(1), 1–8. <https://doi.org/10.1016/j.jocs.2010.12.007>

- [9] Coibion, O., & Gorodnichenko, Y. (2015). Information rigidity and the expectations formation process: A simple framework and new facts. *American Economic Review*, 105(8), 2644–2678. <https://doi.org/10.1257/aer.20110306>
- [10] Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. <https://doi.org/10.1080/07350015.1995.10524599>
- [11] Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On calibration of modern neural networks. ICML. <https://arxiv.org/abs/1706.04599>
- [12] Harvey, D., Leybourne, S., & Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, 13(3), 281–291. [https://doi.org/10.1016/S0169-2070\(96\)00719-4](https://doi.org/10.1016/S0169-2070(96)00719-4)
- [13] Hinton, G., Vinyals, O., & Dean, J. (2015). *Distilling the knowledge in a neural network* (arXiv preprint arXiv:1503.02531). <https://arxiv.org/abs/1503.02531>
- [14] Husted, L., Rogers, J., & Sun, B. (2020). Monetary policy uncertainty. *Journal of Monetary Economics*, 115, 20–36. <https://doi.org/10.1016/j.jmoneco.2019.07.009>
- [15] Kuratov, Y., & Arkhipov, M. (2019). *Adaptation of deep bidirectional multilingual transformers for Russian language* (arXiv preprint arXiv:1905.07213). <https://arxiv.org/abs/1905.07213>
- [16] Lachanski, M., & Pav, S. (2017). Shy of the character limit: "Twitter mood predicts the stock market" revisited. *Econ Journal Watch*, 14(3), 302–345.
- [17] Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. In *Proceedings of the IEEE International*

Conference on Computer Vision (ICCV) (pp. 2980–2988). IEEE.
<https://doi.org/10.1109/ICCV.2017.324>

[18] Loughran, T., & McDonald, B. (2011). When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks. *Journal of Finance*, 66(1), 35–65.
<https://doi.org/10.1111/j.1540-6261.2010.01625.x>

[19] Mankiw, N. G., & Reis, R. (2002). Sticky information versus sticky prices: A proposal to replace the new Keynesian Phillips curve. *Quarterly Journal of Economics*, 117(4), 1295–1328.
<https://doi.org/10.1162/003355302320935034>

[20] Mikosch, H., & Solanko, L. (2017). *Should one follow movements in the oil price or in money supply? Forecasting quarterly GDP growth in Russia with higher-frequency indicators* (BOFIT Discussion Paper No. 19/2017). Bank of Finland Institute for Emerging Economies.

[21] Shapiro, A. H., Sudhof, M., & Wilson, D. J. (2022). Measuring news sentiment. *Journal of Econometrics*, 228(2), 221–243.
<https://doi.org/10.1016/j.jeconom.2020.07.053>

[22] Sims, C. A. (2003). Implications of rational inattention. *Journal of Monetary Economics*, 50(3), 665–690. [https://doi.org/10.1016/S0304-3932\(03\)00029-1](https://doi.org/10.1016/S0304-3932(03)00029-1)

[23] Stock, J. H., & Watson, M. W. (2002). Macroeconomic forecasting using diffusion indexes. *Journal of Business and Economic Statistics*, 20(2), 147–162. <https://doi.org/10.1198/073500102317351921>

[24] Stock, J. H., & Watson, M. W. (2007). Why has U.S. inflation become harder to forecast? *Journal of Money, Credit and Banking*, 39(s1), 3–33.
<https://doi.org/10.1111/j.1538-4616.2007.00014.x>

- [25] Teplova, T., Tomtosov, A., & Sokolova, T. (2022). A retail investor in a cobweb of social networks. *PLOS ONE*, 17(12), e0276924. <https://doi.org/10.1371/journal.pone.0276924>
- [26] Tetlock, P. C. (2007). Giving content to investor sentiment: The role of media in the stock market. *Journal of Finance*, 62(3), 1139–1168. <https://doi.org/10.1111/j.1540-6261.2007.01232.x>